

输出位深相关的图像低阶信号统计：信噪比、量化相位与近黑行为

Low-Order Signal Statistics Related to Image Output Bit Depth:
Signal-to-Noise Ratio, Quantization Phase, and Near-Black Behavior

姜尧耕

<https://y-g-jiang.github.io>

Update:

<https://github.com/y-g-jiang/paper-LOSSRIO>

DOI: 10.5281/zenodo.20894607

摘要—本文研究线性 RAW 输出位深 (16/14/12 bit) 对信号还原能力的影响, 并将其量化为低位深输出与理想线性信号在信噪比、条件均值与误差能量上的相似性。近黑 banding 被建模为带高斯读噪的最近邻量化问题, 核心对象是输出的条件分布及其低阶条件矩。量化输出的特征函数等于输入特征函数以量化频率为周期、带 sinc 权重的复制求和; 对高斯读噪, 一阶和二阶相位谐波中的特征函数及其导数项都带有随读噪与量化步长之比指数衰减的高斯因子。读噪由此充当一个高效的非减性 dither, 将相位相干结构指数压低。在此框架下, 本文给出直接目标位深量化的一阶条件均值偏差闭式傅里叶级数与二阶误差能量的完整傅里叶形式, 并由统一相对容差反解出稳定阈值; 对 16-bit 整数码流再量化到 14-bit 的两级过程, 其 ties-to-even 规则单列离散转移模型 (截位与 half-up 在中心化后与直接量化等价)。对大量相机数据比较 14-bit 与 12-bit 下的信噪比与动态范围差异, 并给出相应的低阶统计判据。本文进一步把该模型推广到一般压扩表: 基波的相位阻尼由组宽序列在输入码上的最小重复长度 P 决定, 因子为 $\exp[-\sigma^2(2\pi/P)^2/2]$ (该描述限于基波主导的范围), 由此给出设计条件 $P \leq \sigma/r_\epsilon$ (量级判据, 非严格的界)、非等宽分组的相位平均量化能量与平滑曲线的直流偏置。在黑电平校正只能取整数的前提下 (DNG 容器的 BlackLevel 本身允许有理数, 故该限定属实现侧而非容器限制), 整数重建把 $\Delta > \sigma/(2r_\epsilon)$ 一支内可用的平均组宽限制为奇整数; 在 4Z 重建约束下穷举表明 ties-to-even 于所验范围内已是最优, 最小 $A_2 = 2.60\%$ (按 E_q 归一为 2.19%), 取到者均为 5、3 交替及其重复。满足噪声比判据的压扩曲线闭式一并写出以作对照: 该形式与广义 Anscombe 变换同形; 以同一比值 σ/Δ 恒定为设计目标、并在根号内带读噪项的写法见 [5] (更一般的根号内偏移见 [7]); 把「同一输出码所覆盖的相邻输入码个数与该处噪声标准差成正比」写成权利要求的授权专利亦已存在 [3]。全部分析限定于线性 RAW 域、最近邻量化与指定的独立同分布高斯

时间读噪模型。

Index Terms—RAW 位深; 16-bit; 14-bit; 12-bit; PDR; 量化噪声; dither; banding; GFX100S; 条件矩; 傅里叶谐波; 特征函数; Sheppard 修正; 压扩表; 有损 RAW 压缩

I. 引言

编码精度的意义建立在其承载的信号信息上。传感器时间读噪与 shot noise 会使最低几位逐帧摆动; PRNU、DSNU、黑场校正残差及后续链路还可能引入固定或相关结构。前一类随机项能够打散量化相位, 此时若直接截位到低位, 数值上的空格不必然对应稳定的量化相位结构, 极端的可以参考类似二值半调的形式。

量化误差是输入的确定性函数, 加性独立噪声只在特定条件下对矩成立 [19]。所以本文给出 s 、读噪 N , 研究条件分布 $P(Y_b | s)$ 和它的各阶条件矩, 如此刻画读噪把确定性结构打散到什么程度。

设理想线性 RAW 信号为 s , 输出位深为 b , 量化输出为 Y_b 。我们关心的是输出相对理想信号的误差

$$e_b(s) = Y_b - s.$$

如果两个位深 b_1, b_2 的误差分布在几个关键统计量上足够接近, 也就是

$$P(Y_{b_1} | s) \approx P(Y_{b_2} | s),$$

那么对这个信号来说, b_1 和 b_2 就是相似的, 在如下三层:

1. 指定目标 SNR 下的 SNR-based DR 损失够小; 其中 PDR 专指 $T_{\text{PDR}} = 16000/PH$ 的情形, 该阈值取

自 Claff 的 Photographic Dynamic Range 定义 (SNR = 20 配弥散圆归一) [8];

2. 条件均值偏差 $B_b(s) = \mathbb{E}[Y_b - s | s]$ 够小;

3. 二阶误差能量 $M_{2,b}(s) = \mathbb{E}[(Y_b - s)^2 | s]$ 的量化相位调制够小;

第一层关心损失多少信噪比, 第二层关心无限堆栈之后会不会留下均值结构, 第三层关心零均值残差的颗粒强弱还会不会随量化相位起伏。本文把条件均值、条件二阶矩等低阶条件统计量中随 $s \bmod \Delta$ 周期变化的部分, 称为低阶量化相位结构; 其中一阶结构对应确定性均值偏置, 二阶结构对应零均值残差的能量调制。

本文所用的结果分两类, 正文各处已就地注明出处, 此处集中列出。属既有结果的重述者: 直接量化下一阶、二阶条件矩的高斯闭式及其指数阻尼, 与 [1] 的式 (33)、(35) 逐式对应 (第 III-A 节); $\Delta^2/12$ 与 Sheppard 修正 [14]; σ/Δ 判据的定性形式 [9] 与定量形式 [4] (第 IV-A 节); 方差稳定的压扩曲线闭式, 与广义 Anscombe 变换同形, 另见 [5], [7], [3] (第 X-A 节); 非均匀量化器的相位平均失真 $\sum_i w_i^3 / (12 \sum_i w_i)$, 为 Bennett 积分的特例 [13] (第 X-B 节); 平滑曲线的常量直流偏置, 即 [5] 的式 (23) (第 X-D 节)。属本文增量者: 把容差 ε 明示化并给出阈值的显式反解与「稳定阈值」定义 (第 VII 节); ties-to-even 两级链路的精确离散模型及其阈值约翻倍 (第 IX 节); 压扩表以输入码上的最小重复长度 P 为控制量的阻尼判据、其前因子闭式与失效范围 (第 X-B 节); 整数重建、零直流与 $4Z$ 约束下的可实现性与穷举结论 (第 X-C 节)。

特别地本文区分两条量化链路。直接目标位深量化写为

$$Y_b^{\text{dir}} = Q_{\Delta_b}(s + N).$$

若连续输入先量化为 16-bit 整数码, 再把该整数码流量化到 14-bit, 则写为

$$Y_{14}^{\text{post}} = T_{16 \rightarrow 14}(Q_1(s + N)),$$

$$T_{16 \rightarrow 14}(n) = 4 \text{round}_{\text{even}}(n/4).$$

这里需要把“16-bit 整数码降到 14-bit”继续分开。字面截位 $4\lfloor n/4 \rfloor$ 与普通 half-up 四舍五入 $4\lfloor n/4 + 1/2 \rfloor$ 在扣除各自的固定码值偏移后, 都是直接 Q_4 的量化相位平移; 它们的相位平均中心化误差能量、最坏相位幅度和任一相同目标 SNR 下的 DR 均与直接 Q_4 相同, 因而在 T_{PDR} 下的 PDR 也相同。NumPy/Python 的 round 采用 ties-to-even, 半步整数码会按粗码奇偶交

替取向, 所得量化单元宽度交替变化, 不能化为一个固定偏移加相位平移。第 III、V 至 VII 节的闭式结果以 Y_b^{dir} 为对象, 同时覆盖截位与 half-up 在上述中心化口径下的等价结果; 第 IX 节单列 ties-to-even 两级模型。相机内部切换 ADC 位深还可能同时改变模拟增益、读出路径和后端噪声, 可以对应模式的实测参数代入。

II. 经典框架: DITHER 与量化的特征函数

A. 量化输出的特征函数

设最近邻量化器

$$Q_{\Delta}(x) = \Delta \text{round}\left(\frac{x}{\Delta}\right),$$

作用在随机变量 X 上。Widrow 的统计量化理论给出量化输出的特征函数等于输入特征函数以 $\Psi = 2\pi/\Delta$ 为周期复制求和 [15], [16], [17]。下式采用 $\text{sinc}(x) = \sin(x)/x$ 。

$$\Phi_{Q_{\Delta}(X)}(u) = \sum_{l=-\infty}^{\infty} \Phi_X(u + l\Psi) \text{sinc}\left(\frac{\Delta(u+l\Psi)}{2}\right).$$

因此, 量化误差里随 s 以量化网格为周期的条件统计量可在格点 $2\pi k/\Delta$ 处分析。一阶条件矩的第 k 个谐波正比于输入特征函数的格点值; 更高阶条件矩还会出现特征函数导数及其组合。高斯特征函数的各阶导数均为多项式乘同一个高斯指数因子。当 $X = s + N$ 、读噪 N 与 s 独立时,

$$\Phi_X\left(\frac{2\pi k}{\Delta}\right) = e^{i2\pi ks/\Delta} \Phi_N\left(\frac{2\pi k}{\Delta}\right).$$

Sripad 和 Snyder 的格点条件给出量化误差边缘分布严格均匀的判据, 即 $\Phi_X(2\pi l/\Delta) = 0, \forall l \neq 0$ [18]。跨样本白性还涉及输入样本对的联合特征函数; 本文在标量格点条件之外另行假设空间与帧间读噪独立。一般高斯输入的格点值不为零, 但会随 $r = \sigma/\Delta$ 快速减小。III-A 节以 $A_2(r) = 12(4r^2 + 1/\pi^2)e^{-2\pi^2 r^2}$ 表示二阶首谐波相对于 $\Delta^2/12$ 的调制, 第 VI 节给出完整二阶级数及其截断余项。

B. 高斯读出噪声的 dithering 行为

对零均值高斯读噪 $N \sim \mathcal{N}(0, \sigma^2)$, 特征函数处处不为零,

$$\Phi_N\left(\frac{2\pi k}{\Delta}\right) = \exp\left[-\frac{1}{2}\left(\frac{2\pi k}{\Delta}\right)^2 \sigma^2\right] = \exp\left[-2\pi^2 k^2 \left(\frac{\sigma}{\Delta}\right)^2\right].$$

这个阻尼因子说明, 高斯读噪不能把任何一阶矩调制严格清零 (高斯特征函数没有实零点), 但能有效压低第

k 个相位相干谐波。第 m 阶条件矩由 dither 特征函数及其至 $m-1$ 阶导数在格点 $2\pi k/\Delta$ 处的值决定，这是非减性 dither 理论的定理 [24], [23]；本文第 V、VI 节取其高斯特例，给出闭式与截断余项界。非减性 dither 的定义、可使低阶矩与输入严格独立的判据及其与本文高斯情形的差别，另见 [22], [25], [20]。记 $r = \sigma/\Delta$ ，主谐波 $k=1$ 的阻尼为 $e^{-2\pi^2 r^2}$ 。高斯输入下量化相位即其小数部分的分布见 [12]。

Clavier 等在 1947 年以特征函数方法给出正弦输入下均匀量化误差的谱 [21]；Bennett 在 1948 年给出高斯过程的对应结果，其中出现高斯阻尼；相关误差的白性还依赖输入的联合统计 [13]。本文不使用该相关函数的具体形式，只取标量格点阻尼推导条件矩。一般地，输入分布越平滑、格点特征函数越小，量化误差越接近量化定理给出的统计模型 [24]。在本文采用的高斯时间读噪模型中，特征函数在格点 $2\pi k/\Delta$ 处给出很强的指数衰减。

III. 量化步长、均匀量化噪声与 SNR-BASED DR

A. 步长与均匀量化噪声

统一用 16-bit DN（记 DN16）做单位，16-bit 最小步长 $\Delta_{16} = 1 \text{ DN16}$ ，直接 14-bit 目标量化的等效步长 $\Delta_{14} = 4 \text{ DN16}$ 。若改用 14-bit ADU 比较 14-bit 与更低位深 b ，量化步长为 $\Delta_b = 2^{14-b}$ 。本节 DR 公式均针对 Y_b^{dir} 。当量化误差与输入低协方差、量化相位又被噪声打散时，均匀量化噪声近似给出经典结果：

$$\sigma_{q,b}^2 = \frac{\Delta_b^2}{12}, \quad \sigma_{q,b} = \frac{\Delta_b}{\sqrt{12}}.$$

这只是信噪比层面的低协方差近似。 $\Delta^2/12$ 需要量化相位被噪声充分随机化。对高斯输入，相关推导见 [35]；本文采用第 VI 节的完整结果。二阶误差能量首谐波的实际半幅为 $\Delta^2\delta(r)$ ，其中

$$\delta(r) = \left(4r^2 + \frac{1}{\pi^2}\right) e^{-2\pi^2 r^2},$$

$$A_2(r) = \frac{\Delta^2\delta(r)}{\Delta^2/12} = 12\delta(r).$$

该式即高斯输入下 Sheppard 修正的残差：[16] 报 $q = \sigma$ 时该残差为 $1.1 \times 10^{-8}\sigma^2$ ，而 $\delta(1)\Delta^2$ 在 $\Delta = \sigma$ 处为 $1.097 \times 10^{-8}\sigma^2$ 。该残差的闭式表达已由 [1] 给出，且是逐式对应的：其式 (33) 为 $\max_{\mu} |\mathcal{E}\{n_q\}| \approx (q/\pi) e^{-2\pi^2\sigma^2/q^2}$ ，除以 q 即本文的 $A_1(r)$ ；其式 (35) 为 $\max_{\mu} \{e_2\} \approx \sqrt{(4\sigma^2 + q^2/\pi^2)^2 + (2(q/\pi)|\mu|_{\max})^2} e^{-2\pi^2\sigma^2/q^2}$ ，其根号

下首项即本文的 $\Delta^2\delta(r)$ （第二项对应输入自身均值的不可控漂移，本文条件化于 s 故不出现）。该文亦已把「对不可控的输入均值取最坏情形、用简单形式的包络函数作上界」确立为口径；由给定容差反解出最小 σ （或固定 σ 时的最大 Δ ）这一步，[16] 同样归于该文。高斯抖动下的相关闭式另见 [2]。本文所做的是将该反解写成 Lambert W 的显式形式（第 VII 节）、取后缀极大以覆盖非单调指标，并把 μ 解释为逐像素真值，从而得到 RAW 位深下的空间相位结构。 $r = 0.5$ 时， $\delta = 7.9206 \times 10^{-3}$ ，故实际半幅为 $7.9206 \times 10^{-3}\Delta^2$ ，相对调制 $A_2 = 9.5047\%$ 。要求 $A_2 \leq 1\%$ 得 $r = 0.619830$ ；解析解及完整级数的余项控制见第 VI、VII 节。平滑渐变中的相干结构还需结合条件分布和空间统计判断。




图 1. 量化前净读噪基线与直接 14-bit 目标量化的 PTC fit DR 材料。左图 RN/FPN=4.729 DN16，右图为直接 Q4 后的 4.868 DN16；直接 Q1 后的 4.7378 DN16 由下式计算。

GFX100S 的 4.729 DN16 是已扣除量化项的净量化前时间读噪（图 1）。对直接 16-bit 与直接 14-bit 目标量化，近黑总噪声分别为

$$N_{16} = \sqrt{4.729^2 + \frac{1}{12}} = 4.7378,$$

$$N_{14} = \sqrt{4.729^2 + \frac{16}{12}} = 4.8679 \quad (\text{DN16}).$$

按目标 SNR 趋近于零的极限估计，最大动态范围差异为

$$\Delta DR_{\max} = \log_2 \frac{4.8679}{4.7378} = 0.0391 \text{ stops}.$$

未发生饱和时，约 0.04 stop 的曝光差可抵消直接 14-bit 目标量化的近黑 SNR 代价，使得全线信噪比表现均优于 16-bit；对应的高光余量也减少约 0.04 stop。若 16-bit 整数码经截位或 half-up 降到 14-bit，扣除固定码值偏移后沿用同一能量结果；若采用 ties-to-even，则两级误差的依赖关系会增加能量，其精确计算见第 IX 节。

B. 任意目标 SNR 下的 DR 与 PDR 特例

设信号电子数 S 、总读出等效噪声 N （电子单位，shot 方差取 S ），则

$$\text{SNR} = \frac{S}{\sqrt{S + N^2}}.$$

给定目标 SNR T ，令 $S/\sqrt{S + N^2} = T$ ，平方后得 $S^2 - T^2S - T^2N^2 = 0$ ，取正根

$$S_T(N) = \frac{T^2 + \sqrt{T^4 + 4T^2N^2}}{2}.$$

若满阱电子数为 F ，则该目标下的 SNR-based DR 为

$$\text{DR}(T; N, F) = \log_2 \frac{F}{S_T(N)}.$$

若 14-bit 与低位深 b 的噪声分别是 $N_{14}(I), N_b(I)$ （ I 为厂标 ISO），并取相同满阱，则低位深达到同一目标 SNR 所损失的 DR 为

$$\Delta\text{DR}_b(T, I) = \log_2 \left(\frac{S_T(N_b(I))}{S_T(N_{14}(I))} \right).$$

PDR 使用 PLT [34] 的固定目标

$$T_{\text{PDR}} = \frac{16000}{PH},$$

$$\text{PDR}(N, F; PH) := \text{DR}(T_{\text{PDR}}; N, F),$$

$$\begin{aligned} \Delta\text{PDR}_b(I) &:= \text{PDR}(N_{14}(I), F; PH) \\ &\quad - \text{PDR}(N_b(I), F; PH) = \Delta\text{DR}_b(T_{\text{PDR}}, I), \end{aligned}$$

其中 PH 为输出图像的像素高度。PDR 是 SNR-based DR 在该固定目标上的专名；任意其他目标 T 下的结果均记为 $\text{DR}(T)$ 或 $\Delta\text{DR}_b(T, I)$ 。

$r = \sigma/\Delta = 0.5$ 时，二阶首谐波半幅为 $\Delta^2\delta(0.5) = 7.9206 \times 10^{-3}\Delta^2$ ，相对于 $\Delta^2/12$ 的调制为 $A_2(0.5) = 9.5047\%$ （III-A 节、第 VI 节与 [35]）。把直接目标位深的量化噪声按低协方差近似并入量化前时间读噪，在相位平均意义下是恒等式： M_2 对 s 在一个完整量化周期上的均匀平均恰等于 $\sigma^2 + \Delta^2/12$ ，对任意 σ 与 Δ 成立（第 VII 节）；逐点口径另需这一相位调制低于所选容差。第 III 节的数值除另行标明者外均取相位平均口径：

$$\begin{aligned} N_{14}(I) &= k_{14}(I) \sqrt{R_{\text{pre},14}(I)^2 + \frac{1}{12}}, \\ N_b(I) &= k_{14}(I) \sqrt{R_{\text{pre},14}(I)^2 + \frac{2^{2(14-b)}}{12}}, \end{aligned}$$

其中 $R_{\text{pre},14}(I)$ 是用 14-bit ADU 表示、已扣除量化项的净量化前时间读噪， $k_{14}(I)$ 是从 ADU 折算到电子或统一噪声单位的比例因子，量纲为电子每 ADU，即该位深下的转换增益（见 IV-B 节）。若输入已经是 14-bit 整数码，再量化到更低位深，需要先指定截位、half-up 或 ties-to-even；前两者在中心化后与直接目标量化等价，ties-to-even 应按离散转移概率重算。

其一，图 2 给出 $T \rightarrow 0$ 噪声底极限下的损失曲线；图 2 与图 3 的横轴均为厂标 ISO，数据点落在以 100 为格点的 1/3 档几何栅格上。在 12-bit 模式可比 14-bit 多获得约 0.2 档曝光且未发生饱和的条件下，对 ISO 1000 以上、图 2 所含 46 款索尼机型中除 A7S3 外的 45 款（截至 2025 年；索尼已属同期噪声表现最好的一批），12-bit 的 SNR-EV 曲线在全部未过曝内容范围内均高于 14-bit。该结论覆盖任意目标 SNR T 。在本节的均匀量化噪声模型内， $\Delta\text{DR}_b(T, I)$ 随 T 增大而减小，其上确界为 $T \rightarrow 0$ 的噪声底极限（记 $x = T^{-2}$ ， $a = N_b^2 > c = N_{14}^2$ ，则 S_T 之比为 $f(x) = \frac{1+\sqrt{1+4ax}}{1+\sqrt{1+4cx}}$ ；以 $u = \sqrt{1+4ax}$ 代换后 $\partial_x \ln f = h(a) - h(c)$ ， $h = \frac{u-1}{2xu}$ 关于 u 递增而 u 关于 a 递增，故 f 严格递增于 x ，即 ΔDR 严格递减于 T ）；当约 0.2 档的额外曝光不小于该上确界时，它足以覆盖全部目标 SNR 下的位深损失。该断言按内容电平逐点成立，故须另计量化相位：ISO 1000 处除 A7S3 外的最大噪声底极限约 0.18 档，对应 $r = 0.52$ 、 $A_2 = 6.8\%$ ，最坏相位另加 0.012 档，合计 0.192 档，仍在该预算内；该结论对这一读数敏感，噪声底极限达 0.186 档时最坏相位合计即抵满 0.2 档。

其二，图 3 给出多机型的横向分布。若只考察 PDR 规定的目标 $T_{\text{PDR}} = 16000/PH$ ，结论可以扩展到更广的机型范围：截至 2025 年，图 3 所含 Canon、Leica、Nikon、Panasonic、Pentax、Samsung、Sony 七个品牌的全部机型，在 ISO 500 以上其 14→12-bit PDR 损失均低于 0.1 档。

C. 像素数与位深 DR 损失

固定传感器面积，固定单位面积满阱容与单位面积读噪功率，只改变像素数 P ，即得位深损失随 P 的标度。

取目标 SNR $T \rightarrow 0$ ，III-B 节的 $\Delta\text{DR}(T)$ 化为噪声底之比。

$$\Delta\text{DR}_{14 \rightarrow 12}^{(T \rightarrow 0)} = \frac{1}{2} \log_2 \frac{R^2 + \Delta_{12}^2/12}{R^2 + \Delta_{14}^2/12} = \frac{1}{2} \log_2 \frac{r^2 + 1/12}{r^2 + 1/192},$$




图 2. $T \rightarrow 0$ 噪声底极限下 14→12-bit 损失随 ISO 的分布 (索尼机型)。

本身, 该量的上确界为 147.5%), 其最坏相位损失为 0.174、0.407 与 0.834 stop, 是表列值的 1.04、1.37 与 1.68 倍; 末行按完整条件矩计, 首谐波截断在该 r 处已差第三位 (给 0.831 与 1.67)。本表的标度结论不受此影响。这个标度依赖两种约定: 定位深、满阱匹配时 $\Delta \propto 1/P$, 单位面积量化功率 $\propto 1/P$; 固定增益时 (Δ 不变、位深随满阱增大) 单位面积量化功率 $\propto P$ 。本文与 PLT 取前者。

- 满阱本身给出与量化无关的另一标度: $\text{FW} \propto 1/P$ 、 $R \propto 1/\sqrt{P}$, 每像素动态范围 $\text{FW}/R \propto 1/\sqrt{P}$, 每减半像素增 $\frac{1}{2}$ stop (表中 $100 \rightarrow 25$ MP, FW/R 由 12.4 升至 13.4 stop)。

IV. BANDING 风险位置

A. 決定比值 $r = \sigma/\Delta$

banding 由量化步长 Δ 、净时间噪声标准差 σ_t 、空间渐变斜率、显示映射和观察尺度一起决定。对本文的直接量化模型，核心无量纲比值是 $r = \sigma_t / \Delta$ 。 r 很小时，输入在量化阈值附近缺少随机抖动，平滑渐变会和量化网格相干； r 够大时，量化相位被打散，一阶均值结构按 $e^{-2\pi^2 r^2}$ 迅速衰减（第 II 节）。该比值判据在数码相机语境下早有讨论：[9] 以「噪声超过量化步长」为准则，并据此判定多款 14-bit 机型的低位不含信息；更早的定量形式见 [4]，其给出步长至多为噪声的 $8/3$ （即 $r > 3/8 = 0.375$ ）作为「无可辨识量化伪影」的界，与

表 I
像素数与 14→12-BIT DR 损失 (STOP)

像素数 (MP)	满阱 (e^-)	读噪 (e^-)	$r = R/\Delta_{12}$	$\Delta DR_{14 \rightarrow 12}^{(T \rightarrow 0)}$	$\Delta DR_{14 \rightarrow 12}(T=20)$
100	8000	1.50	0.768	0.089	0.0011
50	16000	2.12	0.543	0.167	0.0041
25	32000	3.00	0.384	0.298	0.016
12.5	64000	4.24	0.271	0.497	0.057

本文第 VII 节在 $\varepsilon = 1\%$ 下的一阶阈值 $r_{1,\varepsilon} = 0.419$ 相近。本文的增量不在于把定性变定量，而在于给该准则配上明示容差 ε 、一阶与二阶各自的解析阈值 $r_{1,\varepsilon}$ 与 $r_{2,\varepsilon}$ (第 VII 节)，以及阈值的稳定性定义——要求从该点起对一切更大的 r 均满足容差。该定义把阈值的含义固定为「自该点起对一切更大的 r 恒满足容差」；首次穿越阈值 $\inf\{r: A(r) \leq \varepsilon\}$ 同样良定，二者只在指标非单调时才分离。在本文所用的容差下二者处处相同：直接量化的 A_1 在 $r > 0$ 上严格单调下降；其 A_2 在 $r > 0$ 上唯一驻点 $r = 1/(2\pi)$ 之后亦严格单调下降，而 $A_2(0^+) = 12/\pi^2 = 1.216$ 已高于本文一切容差，故首次穿越必落在该驻点之后；第 IX 节两级链路的 A_1 在所扫描的 r 上严格单调下降，其 A_2 虽在 $r \approx 0.37$ 至 0.45 之间有一段回升，但该处 $A_2 \approx 1.3$ 至 1.4 ，同样高于一切容差。故表列各阈值均与首次穿越重合，该定义在本文中不改变任何数；并把该框架推广到两级链路与压扩表 (第 IX、X 节)。

由光子转移特性可知，同一位深下量化步长 Δ 不随信号改变；在把 shot noise 近似为高斯项时，量化前时间噪声 $\sigma_t(m) = \sqrt{\sigma_{\text{read}}^2 + m/K}$ 随信号上升，故 $r = \sigma_t/\Delta$ 在低码值处最小、向亮部增大。这使 r 成为一个可跨亮度比较的保守指标：直接量化的 A_1 与 A_2 都只依赖 r ，故同一 r 处的相对相位结构相同。绝对幅度另带一个标度因子：一阶偏置的幅度为 ΔA_1 ，二阶能量调制的半幅为 $(\Delta^2/12)A_2$ 。这两个标度因子在同一位深内固定 (Δ 不变)，位深内沿信号的变化全部来自 $A_1(r)$ 、 $A_2(r)$ ； Δ 与 Δ^2 的标度只在跨位深比较时另外起作用。本文只给这些统计量，是否可见取决于本文范围之外的感知因素。线性提亮对信号、时间噪声与量化步长同步缩放，不改变 σ_t/Δ 。因此对相同目标感知范围，暗部最低码值处给出较保守的量化相位风险估计 (图 4)。




图 4. PTC 曲线示例。在 shot noise 的高斯近似下，量化前时间噪声随信号升高，所以低码值处给出最小的 σ_t/Δ 。

B. 近黑噪声模型

GFX100S 的 PTC 拟合可分为量化前时间噪声与包含 PRNU 的跨像素总包络 (图 5)。以线性信号码值 m 为自变量：

$$\sigma_{t,\text{DN}}(m) = \sqrt{4.729^2 + \frac{m}{0.71}} \quad \text{DN16},$$

$$\sigma_{\text{all,DN}}(m) = \sqrt{\sigma_{t,\text{DN}}^2(m) + (0.007m)^2} \quad \text{DN16}.$$

m 是线性信号码值。跨像素总包络采用传感器噪声的标准三项结构 $\sigma^2 = \sigma_{\text{read}}^2 + S/g + (\text{PRNU} \cdot S)^2$ (其中 g 即下文的转换增益 K , S 在该式中取 DN16 码值，与第 III-B 节以电子计的 S 不同) (Janesick 式 3.16–3.17, EMVA 1288 线性模型) [26], [27], [28], 各项含义如下：

- 常数项 $4.729^2 = 22.36$ 是已去除量化噪声贡献的净量化前时间读噪方差，该扣除即 Sheppard 修正 [14]；

- 线性项 $m/0.71 = 1.408m$ 是 shot noise 方差，系数是转换增益的倒数， $K = 0.71 \text{ e}^-/\text{DN16}$ （等价 1.408 DN16/e^- ）；
- 二次项 $(0.007m)^2 = 4.9 \times 10^{-5} m^2$ 是跨像素 PRNU 包络， $\text{PRNU} = 0.7\%$ 。它在逐帧时间序列中近似固定，本文不把它计入 $r = \sigma_t/\Delta$ 的 dither 项。

这里的 PRNU 来自对 DPR 标版图像的采样，可能混入标版本身的照度不均与校正残差，因此只用作亮部跨像素包络的估计。近黑 r 由净时间读噪 4.729 DN16 决定。

由此读噪 $4.729 \text{ DN16} \times 0.71 \text{ e}^-/\text{DN16} \approx 3.36 \text{ e}^-$ ，近黑 $m = 0$ 时

$$\sigma_{t,\text{DN}}(0) = 4.729 \text{ DN16}, \quad r = \frac{\sigma_t}{\Delta} = \frac{4.729}{4} \approx 1.18.$$

这就是 GFX100S 近黑的直接量化工作比值，本文第 V 至 IX 节的数值结论建立在这个净时间读噪上。图 6 即可见，在相同的码值跨度上，高码值区域的总噪声更大，因此同一量化步长对应的低阶相位结构更容易被随机项淹没。其中 shot noise 提供逐帧随机化，PRNU 部分只描述空间包络，不能当作独立 dither。

V. 一阶条件均值偏差：确定性均值结构

A. 模型及期望

设量化前 $X = s + N$, $N \sim \mathcal{N}(0, \sigma^2)$ ，直接量化输出 $Y^{\text{dir}} = Q_\Delta(X)$ ，误差 $e = Y^{\text{dir}} - s$ 。固定 s 反复拍、在独立同分布时间读噪的假设下做无限平均：

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n Q_\Delta(s + N_i) = \mathbb{E}[Q_\Delta(s + N) | s].$$

无限堆栈的极限保留条件均值偏差

$$B_\Delta(s) = \mathbb{E}[Q_\Delta(s + N) | s] - s.$$

如果 $B_\Delta(s)$ 随 $s \bmod \Delta$ 周期变化，就有确定性的均值相位结构；如果它低于给定测量容差，则在该容差内没有可分辨的均值相位结构。本节闭式对应直接 $Q_\Delta(s + N)$ ，也给出中心化截位与 half-up 的同幅相移波形；ties-to-even 两级链路的极限偏差见第 IX 节。

B. 闭式傅里叶级数

最近邻量化残差 $q(u) = \text{round}(u) - u$ 是周期函数，锯齿展开为

$$q(u) = \sum_{k=1}^{\infty} \frac{(-1)^k}{\pi k} \sin(2\pi k u).$$

按第 II 节的基本原理对 $X = s + N$ 逐项取期望，第 k 谐波乘上 $\Phi_N(2\pi k/\Delta) = \exp(-2\pi^2 k^2 r^2)$ ，得到

$$B_\Delta(s) = \frac{\Delta}{\pi} \sum_{k=1}^{\infty} \frac{(-1)^k}{k} \exp\left[-2\pi^2 k^2 \left(\frac{\sigma}{\Delta}\right)^2\right] \sin\left(2\pi k \frac{s}{\Delta}\right).$$

$\sin(2\pi k s/\Delta)$ 是量化相位的周期结构，指数项是高斯读噪对它的抹平。

C. 严格上界、截断余项与阈值稳定性

记首谐波项为

$$B_{\Delta,1}(s) = -\frac{\Delta}{\pi} e^{-2\pi^2 r^2} \sin\left(2\pi \frac{s}{\Delta}\right).$$

对完整级数使用 $1/k \leq 1$ 和 $k^2 \geq 1 + 3(k-1)$ ，得到

$$|B_\Delta(s)| \leq \frac{\Delta}{\pi} \sum_{k \geq 1} \frac{1}{k} e^{-2\pi^2 k^2 r^2} \leq \frac{\Delta}{\pi} \frac{e^{-2\pi^2 r^2}}{1 - e^{-6\pi^2 r^2}}.$$

该式给出总幅度的严格上界。对于截断余项 $R_{B,1} = B_\Delta - B_{\Delta,1}$ ，由 $1/k \leq 1/2$ 和 $k^2 \geq 4 + 5(k-2)$ ($k \geq 2$) 进一步得到

$$|R_{B,1}(s)| \leq \frac{\Delta}{2\pi} \frac{e^{-8\pi^2 r^2}}{1 - e^{-10\pi^2 r^2}}.$$

与首谐波幅值相比，

$$\frac{\sup_s |R_{B,1}(s)|}{(\Delta/\pi) e^{-2\pi^2 r^2}} \leq \frac{e^{-6\pi^2 r^2}}{2(1 - e^{-10\pi^2 r^2})} \leq 3.84 \times 10^{-5}.$$

可见在 $r \geq 0.4$ 的阈值区间，首谐波近似的相对截断误差低于 3.84×10^{-5} 。

把直接 16-bit 目标量化写成 Q_1 、直接 14-bit 目标量化写成 Q_4 （都用 DN16），两者期望差 $B_D(s) = B_4(s) - B_1(s)$ ，由三角不等式 $|B_D| \leq |B_4| + |B_1|$ 。 $\Delta = 1$ 的 16-bit 项衰减极快 ($r_{16} = \sigma$)，主导风险来自直接 14-bit 的 $\Delta = 4$ 项 ($r_{14} = \sigma/4$)：

$$|B_D(s)| \leq \frac{4}{\pi} \exp\left[-\frac{\pi^2 \sigma^2}{8}\right] + \frac{1}{\pi} e^{-2\pi^2 \sigma^2}.$$

右端第二项来自 $\Delta = 1$ 一支，在本文工作点为 10^{-192} 量级，写出后该式即为严格上界。设幅度判据是确定性偏置 $< \varepsilon \text{ DN16}$ （此处的 ε 是绝对量，与第 VII 节的无量纲相对容差差一个 Δ 因子： $\varepsilon_{\text{abs}} = \Delta \varepsilon_{\text{rel}}$ ），解 $\frac{4}{\pi} e^{-\pi^2 \sigma^2/8} = \varepsilon$ 得

$$\sigma(\varepsilon) = \frac{2\sqrt{2}}{\pi} \sqrt{\ln\left(\frac{4}{\pi\varepsilon}\right)}.$$

$\sigma(\varepsilon)$ 对判据 ε 仅有对数级依赖，因而极为稳健：




图 5. GFX100S 相关的 PTC 拟合图。近黑净时间读噪给出直接量化模型中最小的 σ_t/Δ 。

表 II
判据 ε 与所需读噪

判据 ε (DN16)	10^{-2}	10^{-4}	10^{-6}	10^{-12}
所需 σ (DN16)	1.98	2.77	3.38	4.75

把判据收紧 4 个数量级 (10^{-2} 到 10^{-6})，所需读噪也才从 1.98 升到 3.38 DN16。而 GFX100S 近黑 $\sigma = 4.729$ DN16，代进去得确定性偏差

$$|B_D| \approx \frac{4}{\pi} e^{-\pi^2(4.729)^2/8} \approx 1.3 \times 10^{-12} \text{ DN16},$$

落在 $\varepsilon = 10^{-12}$ 一档，比一个 16-bit 码低约 12 个数量级 (图 7)。因此，直接 16-bit 与直接 14-bit 目标量化的一阶期望差在该模型下极小。中心化截位与 half-up 只有相位平移，沿用这个幅度；该数值不适用于 ties-to-even 两级模拟。

VI. 二阶矩分布

一阶均值偏差为零不代表误差分布没有结构。一个零均值随机变量照样可以有随输入变化的方差、尾部、偏斜、峰度和空间相关性。对低阶量化相位结构来说，第二个最基础的量是二阶误差能量 $M_{2,\Delta}(s) = \mathbb{E}[(Y - s)^2 | s]$ 。

A. 三项分解

归一化 $\theta = s/\Delta$, $r = \sigma/\Delta$, $Z = N/\Delta \sim \mathcal{N}(0, r^2)$, 归一化总误差 $\eta_\theta = (Y - s)/\Delta = \text{round}(\theta + Z) - \theta =$




图 6. 不同码值范围里的噪声与渐变对照。高码值总包络含 shot noise 与 PRNU；近黑端给出本文直接量化相位模型的最小 σ_t/Δ 。




图 7. 直接 Q1 与 Q4 模型的条件一、二阶矩给出的 RMS 期望差。该图不包含 Q4(Q1) 的整数 tie 效应。

$Z + q(\theta + Z)$ 。于是

$$M_2(\theta) = \mathbb{E}[\eta_\theta^2] = \underbrace{\mathbb{E}[Z^2]}_{\text{读噪能量}} + \underbrace{2\mathbb{E}[Zq(\theta + Z)]}_{\text{交叉项}} + \underbrace{\mathbb{E}[q(\theta + Z)^2]}_{\text{量化残差能量}}.$$

该分解若直接写成读噪方差加 $\Delta^2/12$ ，便默认交叉项与相位项可以略去；这在 SNR-based DR 的均匀量化噪声近似中通常足够，但在二阶相位分析中需要显式保留这些项 (见 VI-C 节)。

B. 傅里叶闭式

量化残差平方的周期展开为

$$q(u)^2 = \frac{1}{12} + \sum_{k=1}^{\infty} \frac{(-1)^k}{\pi^2 k^2} \cos(2\pi k u).$$

两个高斯期望（第二个可由 Stein 引理 $\mathbb{E}[Zg(Z)] = r^2\mathbb{E}[g'(Z)]$ 得到）

$$\mathbb{E}[\cos(2\pi k(\theta + Z))] = e^{-2\pi^2 k^2 r^2} \cos(2\pi k\theta),$$

$$\mathbb{E}[Z \sin(2\pi k(\theta + Z))] = 2\pi k r^2 e^{-2\pi^2 k^2 r^2} \cos(2\pi k\theta).$$

代回三项分解（ q 和 q^2 的傅里叶系数分别是 $O(1/k)$ 、 $O(1/k^2)$ ，乘上 $|\sin|, |\cos| \leq 1$ 再经高斯阻尼后级数绝对收敛，由控制收敛定理保证），得到

$$M_2(\theta) = r^2 + \frac{1}{12} + \sum_{k=1}^{\infty} (-1)^k \left(4r^2 + \frac{1}{\pi^2 k^2} \right) e^{-2\pi^2 k^2 r^2} \cos(2\pi k\theta).$$

乘回 DN16 单位即 $\mathbb{E}[(Q_{\Delta}(s + N) - s)^2 \mid s] = \Delta^2 M_2(s/\Delta)$ 。 $r \rightarrow 0$ 时 $M_2 \rightarrow q(\theta)^2$ （纯量化误差）， $r \rightarrow \infty$ 时 $M_2 \rightarrow r^2 + \frac{1}{12}$ ，趋近均匀量化噪声近似。

C. 截断余项、量级与交叉项

记只保留 $k = 1$ 的二阶近似为

$$M_{2,1}(\theta) = r^2 + \frac{1}{12} - \left(4r^2 + \frac{1}{\pi^2} \right) e^{-2\pi^2 r^2} \cos(2\pi\theta).$$

对余项 $R_{M,1} = M_2 - M_{2,1}$ ，利用 $k \geq 2$ 时 $1/k^2 \leq 1/4$ 及 $k^2 \geq 4 + 5(k - 2)$ ，得到

$$|R_{M,1}(\theta)| \leq \left(4r^2 + \frac{1}{4\pi^2} \right) \frac{e^{-8\pi^2 r^2}}{1 - e^{-10\pi^2 r^2}}.$$

在 $r \geq 0.4$ 时，该余项与二阶首谐波幅值之比不超过 7.68×10^{-5} ；此处将系数比保守地放宽到 1。乘回实际单位后，余项上界还需乘 Δ^2 。

二阶相位谐波同样被指数降低。在 GFX100S 近黑 $r \approx 1.18$ ：首谐波阻尼 $e^{-2\pi^2(1.18225)^2} \approx 1.04 \times 10^{-12}$ ，二阶主相位半幅 $(4r^2 + 1/\pi^2)e^{-2\pi^2 r^2} \approx 5.9 \times 10^{-12}$ ，乘回 $\Delta^2 = 16$ 后约 9.5×10^{-11} DN16²。

交叉项只在小 r 时显著。在 $r = 0.5$ 处，舍去交叉项会使首谐波系数减少 $4r^2 e^{-2\pi^2 r^2} = 0.0071919$ ，对应 $0.0071919\Delta^2$ 的最坏相位误差；同一点截去全部 $k \geq 2$ 谐波的误差上界仅为 $2.7431 \times 10^{-9}\Delta^2$ 。交叉项省略误差与首谐波截断误差由此分开。在 $r \approx 1.18$ 处，首谐波及其交叉项已降至 10^{-11} 到 10^{-12} 量级，更高谐波还受上述余项界约束， $\sigma^2 + \Delta^2/12$ 对该工作点已足够准确（图 8、图 9）。

VII. 一阶与二阶量化痕迹的软过渡

如上所述，读噪是否足以打散量化痕迹由相对读噪 $r = \sigma/\Delta$ 决定。因此同一套判据适用于任意位深、任意量化步长。改变输出位深只是改变 Δ ，真正进入指数衰减项的是 σ/Δ 。

对一阶条件均值，首谐波的无量纲幅度为

$$A_1(r) = \frac{1}{\pi} \exp(-2\pi^2 r^2),$$

它度量量化误差均值随输入相位起伏的首谐波强度。这个量若仍然较大，误差均值便含有空间相干结构，平均、堆栈或局部积分之后仍可能留下稳定的等级边界。完整偏置与该指标之间的误差由 V-C 节的余项界控制（图 10）。

对二阶误差能量，首谐波的归一化幅度为

$$A_2(r) = 12 \left(4r^2 + \frac{1}{\pi^2} \right) \exp(-2\pi^2 r^2),$$

它对应的是误差二阶矩（能量）随输入相位起伏的强度，并以同一量化步长下的均匀量化误差方差 $\Delta^2/12$ 归一化；二阶误差能量的实际主相位半幅为 $(\Delta^2/12)A_2(r)$ 。该容差并非外生量。低协方差近似正是把 $\Delta_b^2/12$ 并入量化前读噪；对直接量化， M_2 在一个完整量化周期上对 s 的均匀平均恰等于 $\sigma^2 + \Delta^2/12$ （该式对任意 σ 与 Δ 成立，是恒等式而非近似，也不依赖误差独立假设），而 A_2 即这一项相对自身的相位调制半幅。故 $A_2 = \varepsilon$ 的容差等价于所报 16 $\rightarrow$ 14 bit DR 损失有 ε 量级的相对记账误差，其比例系数在本文工作点、 $T \rightarrow 0$ 时为 1.04。该比值随 T 与 σ 单调上升—— $T \rightarrow 0$ 给出的是其下端而非上界——在 $\sigma \in [2, 16]$ DN16 上为 0.936 至 1.065，一致上界为 $\Delta_{14}^2/(\Delta_{14}^2 - \Delta_{16}^2) = 16/15$ 。取 $\varepsilon = 1\%$ 因而等价于要求该记账误差不超过 1.07%。两点限定：其一，上式只对直接量化成立，第 IX 节两级链路的相位平均能量为 $\sigma^2 + 19/12$ ，同一比值在工作点降为 0.861ε ，其一致上界为 $8/9$ （在 $\sigma \rightarrow \infty$ 处取到）（此处的 A_2 按 $\Delta_{14}^2/12$ 归一；若改按相位平均量化能量 $19/12$ 归一，同一修正表现为系数 1.022、极限 $19/18$ ，二者不可叠乘）；其二， ε 是阈值 r_ε 处的口径，不是本文工作点上的误差棒——工作点 $r = 1.182$ 处 $A_2 = 7.1 \times 10^{-11}$ ，该处的记账误差远在任何有效数字之下。给定统一相对容差 ε ，直接量化的两个首谐波阈值由 $A_1(r) = \varepsilon$ 与 $A_2(r) = \varepsilon$ 确定：

$$r_{1,\varepsilon} = \sqrt{\frac{\ln[1/(\pi\varepsilon)]}{2\pi^2}},$$


高斯自然 dither 的相位调制随 σ/Δ 增大而指数衰减

图 8. 高斯读噪下四个 σ/Δ 处的一阶均值偏差与二阶噪声能量调制的相位波形。二阶面板的纵轴为相对总方差 $\sigma^2 + \Delta^2/12$ 的调制，与正文以 $\Delta^2/12$ 归一的 A_2 相差 $1 + 12r^2$ 倍（ $r = 0.5$ 处 4.00、 $r = 1.18$ 处 17.8）。




图 10. 直接量化的一阶、二阶首谐波幅度随相对读噪 $r = \sigma/\Delta$ 的衰减。蓝线为 A_1 ，紫线为相对于 $\Delta^2/12$ 归一化的 A_2 。

$$r_{2,\varepsilon} = \frac{1}{2\pi} \sqrt{-2W_{-1}\left(-\frac{\pi^2\varepsilon}{24\sqrt{e}}\right) - 1}.$$

其中 W_{-1} 为 Lambert W 函数的 -1 分支。取 $\varepsilon = 1\%$ ，得到 $r_{1,\varepsilon} = 0.418698$ 、 $r_{2,\varepsilon} = 0.619830$ 。在这两个阈值处，一阶偏置余项不超过 $1.551 \times 10^{-7}\Delta$ ，二阶余项相对于 $\Delta^2/12$ 不超过 1.256×10^{-12} ；完整级数与首谐波阈值在本文列示精度内一致。 $r = 0.5$ 与 $r = 0.75$ 两处的相位波形见图 11、图 12。容差收紧到 0.1% 时，两者分别为 0.540 与 0.718；收紧到 0.01% 时分别为 0.639 与 0.801。

把上述解析首谐波阈值取一位小数，可得到更便于使用的直接量化工程分区：

若能取得某机内 12-bit 模式下已扣除量化项的净时间读噪，并以 DN12 表示，则该模式的 $\Delta = 1$ ，数值本身就是 r 。例如 OM-1 Mark II 在最低原生 ISO 下若有 0.7 DN12，直接量化模型给出一阶主谐波 $A_1 \approx$


实用范围放大： $\sigma/\Delta = 0.5$ 已很小，GFX100S 近黑已不可见地平

图 9. 实用范围放大： $\sigma/\Delta = 0.5$ 位于直接量化的二阶主导过渡区，GFX100S 近黑处的相位调制更低。二阶面板的归一口径同图 8，一阶面板则与正文的 A_1 同口径。图内标题就 $\sigma/\Delta = 0.5$ 所作的可见性表述不属本文结论：该处 $A_2 = 9.5\%$ ，高于本文所用的一切容差，而可见性本身取决于第 IV-A 节所述本文范围之外的感知因素。

2.0×10^{-5} 。无限堆栈趋于 $s + B_\Delta(s)$ ，相位偏差很小但不严格为零；单帧还可能保留约 $1.30 \times 10^{-4} \Delta^2$ 的二阶主调制。



对直接目标位深量化，可把对应步长写成 Δ 后考察 $r = \sigma/\Delta$ 。以 S5M2 为例，若 14-bit 下 ISO 100 的净时间 RNDN 为 1.2 ADU14，截位至 12-bit 目标量化近似时有 $r = 1.2/4 = 0.3$ ，一阶与二阶残留都较明显；ISO 400 若为 3.4 ADU14，则 $r = 0.85$ ，一阶主谐波约 $2.0 \times 10^{-7}\Delta$ ，二阶主调制约 $1.9 \times 10^{-6}\Delta^2$ 。若处理对象是既有 14-bit 整数码流再量化到 12-bit，截位与 half-up 在中心化后沿用直接量化幅度，ties-to-even 等依赖粗码奇偶的规则应按第 IX 节同类方法重算。实际 S5M2 的 12-bit 直接输出模式更为复杂，其读出后续一些 isp 操作实际运行在高位深中。

对机内 ADC 状态直接改变到 14-bit 输出的情况，例如 GFX-100 的行为，他在 16-bit 下净读出噪声约为 5.4 ADU16，而在 14-bit 下净读出噪声约为 1.4 ADU14，直接模型预期的一、二阶量化相位调制很低。

VIII. 补充说明条件矩到低阶量化相位结构

第 V、VI 节给出的是条件矩。但 banding 本质上是空间相干现象，因此这里说明逐点条件矩如何约束低阶量化相位结构。

在本文的空间独立时间读噪模型中，稳定的量化相位条带需要误差里存在随 s 确定性变化的相干分量。第 V、VI 节已给出一阶均值和二阶误差能量的相位谐波；对高斯读噪，这些低阶项都含 $e^{-2\pi^2 k^2 r^2}$ 。GFX100S 近

图 11. 在 $r = 0.5$ 下，一阶均值相位结构和二阶能量调制的相位波形。图 12. 在 $r = 0.75$ 下，一阶均值相位结构和二阶能量调制的相位波形。表 III
直接量化的工程分区

工程范围	低阶相位结构的量级解释
$r < 0.4$	一阶、二阶通常仍在 1% 量级或更高
$0.4 \leq r < 0.6$	一阶穿过 1% 阈值，二阶仍占主导
$0.6 \leq r < 0.7$	二阶穿过 1% 阈值，并向 0.1% 量级衰减
$0.7 \leq r < 0.8$	二阶由约 0.1% 向 0.01% 量级衰减，弱残留区
$r \geq 0.8$	一阶、二阶均均在 0.01% 量级或更低

黑 $r \approx 1.18$ 时, $k = 1$ 的指数因子约为 1.0×10^{-12} , 所以直接量化模型的一阶均值结构与二阶能量调制都很低, 剩余项的能量接近 $\sigma^2 + \Delta^2/12$ 。该结论限于直接量化: 直接量化在该工作点的 $A_2 = 7.1 \times 10^{-11}$ (第 VII 节), 而第 IX 节的两级 ties-to-even 链路给出 $A_2 = 2.60\%$, 高 3.7×10^8 倍, 可见降位深的舍入规则本身即是模型内的放大项。

条件矩不能排除模型之外的 banding。若读噪在空间上相关, 或存在 DSNU、列噪声、行噪声、黑电平校正残差, 和 s 不相干的项也可能形成条带; 这类结构需要协方差、二维功率谱或重复帧固定图样分解来检验。显示侧 banding 还受位的分配方式 (编码曲线、gamma、LUT) 影响, 名义位数只能提供部分信息 [30], [31], [32], [33]。

IX. 两级量化情形与更多可视化解释

A. ties-to-even 的两级量化模型

与前文不同, 相当多的程序在降位深时得到的是 ties-to-even——例如 NumPy 的 `round` 采用 round-half-to-even (IEEE-754 的默认舍入方向) 即为此; 此处 $n/4$ 恰落在半整数上, 不涉及十进制半值在二进制下的表示问题。这一情形被量化理论明确排除在外: [17] 的附录 J (Digital Dither, J.1.1 节) 在讨论再量化时点名 convergent rounding (输入恰在两个可表示数中点

时取向偶数), 并写道「量化理论不处理这些情形」, 随后给出四条退而求其次的处置——接受 convergent rounding 把偏置平均掉、假定落在半步处的概率很小、假定数字 dither 的步长远小于量化步长、或改写舍入以符合理论。本节是该情形在高斯读噪下的定量补全, 结果落在前两条上: 第一条只对一阶成立 (固定码值偏移确为零, 但留下二阶相位调制, 见 IX-C1 节), 第二条在 $16 \rightarrow 14$ bit 的整数再量化中必然失效 (每 4 个输入码就有 1 个精确落在半步处)。须区分的是, 本文的读噪是加在第一级之前的连续 dither, 与该附录所讨论的、加在再量化之前且步长与输入数据同为整数的数字 dither 不是同一对象。同一情形在图像取证的双量化文献中另有一条结论与之相关。[11] 的 4.2 节以 $n(v)$ 记并入第 v 个输出码的输入码个数, 指出它以第一级步长为周期、该周期性正是双量化直方图伪影的来源; 并指出当两级步长之比为整数时 $n(v)$ 恒等于第二级步长, 此时双量化与以第二级步长直接单量化的直方图相同、二者不可区分。本文的两级链路正属该整数比情形 (第一级步长为 1、第二级为 4)。该结论以截位推导 (其脚注称取整版本类似), 而按本节的三条规则逐一代入: 截位与 half-up 确给出恒为 4 的 $n(v)$, 与下文 IX-A1 节所述二者中心化后等价于直接 Q_4 一致; ties-to-even 则给出 5、3 交替的 $n(v)$ (输出 0 并入 $n \in \{-2, \dots, 2\}$ 共 5 个码, 输出 4 并入 $n \in \{3, 4, 5\}$ 共 3 个码, 因

$n = \pm 2, 6$ 处的平局均取向偶数)，故该结论的适用范围不含 ties-to-even。其效果是固定码值偏移为零（表 IV 列的是校正量 c ，截位与 half-up 分别为 $+3/2$ 与 $-1/2$ ，即偏移的相反数），故在无法规范小数黑电平时不引入无法消去的常量黑电平偏移；代价是相位平均量化能量由 $16/12$ 升至 $19/12$ 。

但如图 13-15 为先计算 $Q_1(s + N)$ ，再用 NumPy 最近邻 ties-to-even 得到 14-bit 码，以此不会损失线性度，不过会引入更新的 banding 影响因素。这条链路对应 Y_{14}^{post} ，与第 V、VI 节的直接 $Q_4(s + N)$ 解析式不同。令 $n = Q_1(s + N) \in \mathbb{Z}$ ，则

$$p_n(s) = \Phi\left(\frac{n + 1/2 - s}{\sigma}\right) - \Phi\left(\frac{n - 1/2 - s}{\sigma}\right),$$

$$T(n) = 4\text{round}_{\text{even}}(n/4),$$

其中 Φ 为标准正态分布函数（与第 II 节的特征函数 Φ_X 同名不同义）。两级模型的条件均值偏差和二阶误差能量可直接求和：

$$B_{\text{post}}(s) = \sum_{n \in \mathbb{Z}} T(n)p_n(s) - s,$$

$$M_{2,\text{post}}(s) = \sum_{n \in \mathbb{Z}} [T(n) - s]^2 p_n(s).$$

在 $\sigma = 4.729 \text{ DN16}$ 下，对 $s \bmod 8$ 精确扫描得到

$$\max_s |B_{\text{post}}(s)| = 9.85 \times 10^{-4} \text{ DN16},$$

$$\frac{\max_s M_{2,\text{post}} - \min_s M_{2,\text{post}}}{2} = 3.47 \times 10^{-2} \text{ DN16}^2.$$

后者约占相位平均误差能量 23.9468 DN16^2 的 0.145%。该平均能量比直接 Q_4 的 $4.729^2 + 16/12 = 23.6968 \text{ DN16}^2$ 高 0.25 DN16^2 ，来源是 ties-to-even 把复合单元宽度改成 5、3 交替，使 $\sum_i w_i^3 / (12 \sum_i w_i)$ 由 $16/12$ 升到 $19/12$ ；该量是单元宽度的几何量，与 σ 无关。按相位平均误差能量估计，两级 $16 \rightarrow 14$ -bit 相对直接 16-bit 的近黑 DR 极限损失为 $\frac{1}{2} \log_2 [23.9468 / (4.729^2 + 1/12)] = 0.0467 \text{ stop}$ 。两级结果显著高于直接 Q_4 的 $1.33 \times 10^{-12} \text{ DN16}$ 与 $9.49 \times 10^{-11} \text{ DN16}^2$ ，量级仍小于单帧随机波动。

两级输出的 500 帧均值标准误差为 $\sqrt{23.9468/500} = 0.2188 \text{ DN16}$ 。图 13 的浅蓝带是模拟所用量化前噪声 σ_{sim} （近黑处为 4.729 DN16 ）给出的 $\sigma_{\text{sim}}/\sqrt{500} \approx 0.2115 \text{ DN16}$ 参考带，宽度比两级输出的标准误差低约 3.4%；图内现已分别标明这两个量。图 13、图 14 无法分辨上述两套模型的相干偏差，只能

展示有限帧随机残差的外观。原模拟还在 σ_{sim}^2 中保留了 $(0.007m)^2$ ，但在图示 $0 \leq m \leq 7.5 \text{ DN16}$ 内，该项对总方差的贡献低于 0.013%，不参与本文的 dither 论证。

1) 截位、普通四舍五入与 ties-to-even：对非负 RAW 整数码 n ，三种转移规则为

$$T_{\text{floor}}(n) = 4\lfloor n/4 \rfloor, \quad T_{\text{half-up}}(n) = 4\lfloor n/4 + 1/2 \rfloor,$$

$$T_{\text{even}}(n) = 4\text{round}_{\text{even}}(n/4).$$

对每条链路加入表中的固定码值校正 c ，定义其相对连续含噪输入的完整误差函数 $g_T(x) = T(Q_1(x)) + c - x$ 。一个周期内的有效量化单元直接给出下表，横线表示对该完整周期的均匀平均。

截位和 half-up 校正后都是单元宽度为 4、重建值位于单元中心的均匀量化器，只与直接 Q_4 相差网格相位。因此它们的一阶、二阶条件矩波形只发生横向相移，第 VII 节的幅度阈值和第 III 节的 DR 表达式无需重算；取目标 SNR $T = T_{\text{PDR}}$ 时（此处的 T 为第 III-B 节的目标 SNR，与本节的转移映射 $T(\cdot)$ 同名不同义），PDR 也相同。在 $\sigma = 4.729 \text{ DN16}$ 、black level 与四码分组对齐时，原始输出的固定偏移分别约为 -1.5 与 $+0.5 \text{ DN16}$ ；校正后相位平均 MSE 均为 23.6968 DN16^2 ，相对直接 Q_1 的近黑 DR 极限损失均为 0.0391 stop 。

ties-to-even 在半步整数码处按粗码奇偶交替取向，形成宽度 5、3 交替的单元，无法用固定偏移化为均匀 Q_4 。它的相位平均量化 MSE 为 $19/12 \text{ DN16}^2$ ，比前三条等价链路多 $1/4 \text{ DN16}^2$ ；严格积分见 IX-C3 节。固定信号相位下仍以 IX-A 节的 $p_n(s)$ 离散和为准。

B. 空间观察

图 13-15 是对一行渐变进行采样的结果：

图 13-15 使用单行剖面展示量化后的离散跳变，是为了把逐像素码值跳动直接暴露出来。实际视觉判断发生在二维空间中。

另外，单行曲线在几个码值之间跳动，只说明数字样本是离散的；它本身并不等价于可见 banding。图 16、图 17 给出一个极端的例子，其图像完全由纯白和纯黑组成：

二值半色调说明，局部像素值即使高度离散，经过空间采样与视觉积分后仍可能形成连续灰度感。它只提供空间积分的类比，不能替代 RAW 量化模型；这个例子用于说明几个码值上下跳本身不足以证明存在可见台阶。

表 IV
三种转移规则的中心化误差统计

规则	校正 c (DN16)	有效单元宽度	$\overline{g_T}$	$\overline{g_T^2}$ (DN16 ²)
截位	+3/2	均匀 4	0	16/12
half-up	-1/2	均匀 4	0	16/12
ties-to-even	0	5、3 交替	0	19/12




图 13. GFX100S 低码值平滑渐变的单帧与 500 帧平均。上行为直接 Q1，下行为两级 Q4(Q1) ties-to-even。浅蓝带为量化前 $\sigma_{\text{sim}}/\sqrt{500}$ 参考，两级 14-bit 输出的标准误差为 0.2188 DN16。




图 14. 不同平均帧数下直接 Q1 与两级 Q4(Q1) ties-to-even 输出的有限样本比较。该图展示堆栈中的随机收敛，不用于估计解析相干偏差。




图 15. 单帧直接 Q1 与两级 Q4(Q1) ties-to-even 的分排对比。

C. 两级模型的相位结构、主导区与 DR 行为

1) 与直接量化一致的阈值口径：把第 VII 节的阈值口径用于两级离散转移模型。令 $r = \sigma/\Delta_{14}$ ，并在一个完整的 $s \bmod 8$ 周期内取最大相位幅度，定义

$$A_{1,\text{post}}(r) = \frac{\max_s |B_{\text{post}}(s)|}{\Delta_{14}},$$

$$A_{2,\text{post}}(r) = \frac{\frac{1}{2}[\max_s M_{2,\text{post}}(s) - \min_s M_{2,\text{post}}(s)]}{\Delta_{14}^2/12}.$$

$A_1 \leq \varepsilon$ 与 $A_2 \leq \varepsilon$ 使用同一个无量纲相对容差。前者是条件均值偏置相对于一个量化步长的比例，后者是二阶误差能量相位调制相对于均匀量化误差方差 $\Delta_{14}^2/12$ 的比例。两级指标取完整离散和的相位极值；直接量化参考取第 VII 节的首谐波解析指标 $A_{1,\text{dir}} = \pi^{-1}e^{-2\pi^2 r^2}$ 与 $A_{2,\text{dir}} = 12(4r^2 + \pi^{-2})e^{-2\pi^2 r^2}$ 。第 V、VI 节的余项界保证直接量化曲线在表列阈值附近与完整级数一致到所示精度。

对任一指标 $A(r)$ ，稳定阈值定义为 $r_\varepsilon = \inf\{r : A(r') \leq \varepsilon, \forall r' \geq r\}$ 。该定义容许两级离散模型出现非单调起伏：其 A_2 在 $r \approx 0.37$ 至 0.45 之间有一段回升。该区段 A_2 本身在 10^0 量级，远高于本节所用的容差，不影响阈值取值。

数值实现取 $\Delta_{14} = 4$ 、 $\sigma = 4r$ ，在 $0 \leq s < 8$ 上使用 4096 个等间隔相位，并对 $n \in [-12\sigma - 3, [8 + 12\sigma + 3] \cap \mathbb{Z}]$ 计算 IX-A 节的离散和。被截去的高斯尾概率低于 4×10^{-33} 。随后在 $0.03 \leq r \leq 2.5$ 上作对数扫描，以后缀最大值确定稳定交点，并在交点邻域作对数插值。将相位数增至 8192 和 16384 后，1% 阈值在 10^{-6} 精度



图 16. 二值半色调示例。局部只有黑白，但空间积分之后形成连续灰度感。



图 17. 二值半色调的照片示例。视觉系统会在一定尺度上做空间整合。




图 18. 两级 Q4(Q1) ties-to-even 的完整离散相位幅度与直接量化的首谐波解析参考。四条曲线使用同一归一化口径；横向虚线给出 1%、0.1%、0.01% 三档相对容差，竖向点划线标出 GFX100S 的 $r = 1.182$ 。

内仍保持为 0.804391 与 1.273439。该检验只说明相位扫描已收敛；实现本身另由第 X-B 节的解析谐波闭式独立复核——两条路径在所试序列上给出的 A_1 、 A_2 逐位一致，两个阈值亦完全重合。

两级阈值约为直接量化阈值的两倍，这一尺度来自基本周期的扩展。定义 $e_{\text{dir}}(x) = Q_4(x) - x$ 与 $e_{\text{post}}(x) = T(Q_1(x)) - x$ ，两者的周期分别为 4 和 8 DN16。

周期为 P 的函数经方差为 σ^2 的高斯卷积后，第 k

个傅里叶分量带有阻尼

$$G_P(k) = \exp \left[-\frac{\sigma^2}{2} \left(\frac{2\pi k}{P} \right)^2 \right].$$

对条件偏置有 $B(s) = \mathbb{E}[e(s+N)]$ ；对二阶矩有 $M_2(s) = \sigma^2 + 2\mathbb{E}[Ne(s+N)] + \mathbb{E}[e^2(s+N)]$ 。高斯分部积分给出

$$\mathbb{E}[Ne(s+N)] = \sigma^2 \frac{d}{ds} \mathbb{E}[e(s+N)].$$

因此， M_2 的非零谐波也带有 $G_P(k)$ ，交叉项只改变其多项式系数和相位。

取 $\sigma = 4r$ ，两个基本频率的阻尼分别为

$$G_4(1) = e^{-2\pi^2 r^2}, \quad G_8(1) = e^{-\pi^2 r^2/2}.$$

指数中 r^2 的系数相差 4 倍，达到相近衰减量所需的 r 因而约相差 $\sqrt{4} = 2$ 倍。数值上， $0.804/0.419 = 1.92$ ， $1.273/0.620 = 2.05$ 。与 2 的偏差来自两个量化器的基波系数不等，其具体值还取决于 ε ： $\varepsilon = 0.1\%$ 与 0.01% 时一阶比为 1.95 与 1.97、二阶比为 2.04 与 2.03，两者均向 2 趋近。高次谐波与相位极值在此不起作用：把两级一侧的谐波截到 $k \leq 1$ 、 $k \leq 2$ 与 $k \leq 8$ ，所得阈值到小数第六位相同。二阶的 2.05 则实质依赖交叉项：把两级一侧的 $2\sigma^2(i2\pi k/P)\hat{g}_k$ 去掉后两级阈值由 1.273 降到 0.678，该比值降到 1.09（两侧同去则为 1.37）。

得到 ties-to-even 两级模型的工程分区：

GFX100S 近黑 $r = 4.729/4 = 1.18225$ 落在工程分区 $0.8 \leq r < 1.3$ ，即两级模型的二阶主导过渡区。离散求和给出

$$A_{1,\text{post}} = 2.461 \times 10^{-4} = 0.0246\%,$$

表 V
两级与直接量化的稳定阈值 r_ϵ

相对容差 ϵ	两级 r_ϵ (A1)	两级 r_ϵ (A2)	直接首谐波 r_ϵ (A1)	直接首谐波 r_ϵ (A2)
1%	0.804	1.273	0.419	0.620
0.1%	1.055	1.464	0.540	0.718
0.01%	1.257	1.629	0.639	0.801

表 VI
TIES-TO-EVEN 两级模型的工程分区

工程范围	低阶相位结构的量级解释
$r < 0.8$	一阶、二阶尚未稳定低于 1%
$0.8 \leq r < 1.3$	一阶穿过 1% 阈值，二阶仍占主导
$1.3 \leq r < 1.5$	二阶穿过 1% 阈值，并向 0.1% 量级衰减
$1.5 \leq r < 1.6$	二阶由约 0.1% 向 0.01% 量级衰减，弱残留区
$r \geq 1.6$	一阶、二阶均约在 0.01% 量级或更低




图 19. 一阶、二阶相位结构的稳定阈值曲线。横轴为统一相对容差 ϵ ，纵轴为从该点起始终满足容差所需的最小 r_ϵ 。实线为两级完整离散模型，虚线为直接量化的首谐波解析参考。

$$A_{2,\text{post}} = 2.604 \times 10^{-2} = 2.604\%.$$

相同工作点的一阶峰值偏置是 9.85×10^{-4} DN16，二阶误差能量半极差是 3.47×10^{-2} DN16²。500 帧平均的标准误差为 0.2188 DN16，远大于一阶偏置；按最大偏置相位计算，随机均值标准误差降到该偏置量级约需 2.47×10^7 帧。普通单帧与有限堆栈主要受二阶能量控制，无限堆栈的极限才由未消失的一阶偏置决定。

2) 码值—像素阶梯与固定相位：这里的信号相位是连续均值 s 相对量化网格的位置。直接 Q1 和直接 Q4 同样有相位依赖；它们的 $B(s)$ 与 $M_2(s)$ 分别以 1 和 4 DN16 为周期。两级 ties-to-even 链路因粗码奇偶交替，基本周期扩展到 8 DN16。




图 20. 无噪声线性渐变 $s(x) = x/4$ DN16 的码值—像素阶梯。直接 Q1 每隔 1 DN 跳变，直接 Q4 的均匀单元宽 4 DN，两级 Q4(Q1) ties-to-even 出现 3、5 DN 交替单元。该图只解释阈值与网格相位，不包含读噪。

3) 相位平均 MSE 与近黑 DR 极限：固定信号相位下，Q1 误差、ties-to-even 映射和读噪通过同一个整数码耦合， $M_{2,\text{post}}(s)$ 始终由 IX-A 节的离散和计算。本

节再对均匀相位平均：

$$\overline{M_2} := \frac{1}{8} \int_0^8 M_2(s) ds.$$

定义完整等效量化误差 $g(x) = T_{\text{even}}(Q_1(x)) - x$ ，则最终误差为 $e = N + g(s + N)$ 。 g 以 8 为周期；一个周期内，重建值 0 和 4 对应的单元分别为 $[-5/2, 5/2)$ 与 $[5/2, 11/2)$ ，宽度为 5 和 3。故

$$\bar{g} = 0, \quad \bar{g^2} = \frac{1}{8} \left(\int_{-5/2}^{5/2} x^2 dx + \int_{-3/2}^{3/2} x^2 dx \right) = \frac{19}{12}.$$

对任一固定噪声实现 $N = z$ ，周期平移不改变上述积分，因此

$$\frac{1}{8} \int_0^8 [z + g(s + z)]^2 ds = z^2 + \frac{19}{12}.$$

交叉项在这个周期积分下严格为零；该结论不使用误差独立假设。再对 $N \sim \mathcal{N}(0, \sigma^2)$ 取期望，得到

$$\overline{M_{2,\text{post}}} = \sigma^2 + \frac{19}{12} = \Delta_{14}^2 \left(r^2 + \frac{19}{192} \right).$$

作为比较，直接 Q1 与直接 Q4 的相位平均 MSE 分别为

$$\overline{M_{2,Q1}} = \Delta_{14}^2 \left(r^2 + \frac{1}{192} \right), \quad \overline{M_{2,Q4}} = \Delta_{14}^2 \left(r^2 + \frac{1}{12} \right).$$

以 $\sqrt{\overline{M_2}}$ 定义相位平均等效噪声，在目标 SNR $T \rightarrow 0$ 的近黑极限，

$$\Delta \text{DR}_{\text{post}/Q1}^{(T \rightarrow 0)} = \frac{1}{2} \log_2 \frac{r^2 + 19/192}{r^2 + 1/192},$$

$$\Delta \text{DR}_{Q4/Q1}^{(T \rightarrow 0)} = \frac{1}{2} \log_2 \frac{r^2 + 1/12}{r^2 + 1/192},$$

$$\Delta \text{DR}_{\text{post}/Q4}^{(T \rightarrow 0)} = \frac{1}{2} \log_2 \frac{r^2 + 19/192}{r^2 + 1/12}.$$

相位平均近黑 DR 极限可在一阶、二阶相位调制已经很低时继续存在，因为前者取决于平均 MSE，后两者只计随 s 周期变化的相干部分。GFX100S 工作点的两级总代价为 0.04666 stop，其中直接 Q4 部分为 0.03909 stop，tie 附加量为 0.00757 stop。同一工作点下，两级 $M_{2,\text{post}}(s)$ 在 $s = 0 \pmod{8}$ 取 23.9121 DN16²，相位平均为 23.9468 DN16²，在 $s = 4 \pmod{8}$ 取 23.9815 DN16²；固定相位近黑 DR 极限的峰峰范围为 0.00209 stop。




图 21. 两级 Q4(Q1) ties-to-even 的相位平均 MSE 与近黑 DR 极限。紫线为两级链路相对直接 Q1 的总代价，蓝色虚线为直接 Q4 相对直接 Q1，橙色点线为两级链路相对直接 Q4 的 tie 附加量。

X. 压扩曲线与压扩表的相位结构

第 IX 节的两级模型针对 ties-to-even 这一条特定规则。本节起 b 表示一个周期内的组数，与第 I 节的输出位深同名不同义。本节把该模型推广到一般的压扩表：给出条件矩各阶谐波的阻尼闭式，第 k 阶为 $\exp[-\sigma^2(2\pi k/P)^2/2]$ ，其前因子由组宽序列与 d_i 决定、本节按数值给出；其中基波的阻尼为 $\exp[-\sigma^2(2\pi/P)^2/2]$ ， P 为组宽序列在输入码上的最小重复长度；由此给出设计条件 $P \leq \sigma/r_\epsilon$ 与二阶容差阈值，并给出该描述的失效范围。组宽序列的重复结构会影响压扩表的表现，这一点在天文有损压缩中已有报告：[5] 把压扩表定义为步长增量的重复整数序列 $\{s_i\}$ ，并指出应优先选取尽量均匀的序列、较长的 $\{s_i\}$ 其偏置修正更复杂且精度更低；[6] 则观测到在噪声已足以 dither 的条件下，整数定义域与整数值域的平方根编码仍留下系统性偏移。压扩表并非假想对象：有损 RAW 格式普遍用它把码值域压到更少的位数（其逆表在 DNG 规范中由 LinearizationTable 承载 [38]）。须区分的是，同一格式中往往另有与压扩表无关的有损环节——例如 ARW2 的块内差分编码，其在高对比边缘附近产生的平行线状伪影与 posterization 已有实证报告与基于逐像素取值不确定度的纹理合成修复工具 [10]；本节只讨论压扩表这一环，两者机制不同。与该类事后修复工作互补，本节给出的是设计侧的约束。

A. 由判据反推的压扩曲线

若要求全码值域上量化前总噪声与步长之比不低于给定阈值 r^* ，则步长须满足 $\Delta(m) \leq \sigma_t(m)/r^*$ 。码值分配为步长的倒数积分，对第 IV-B 节的噪声模型 $\sigma_t(m) = \sqrt{\sigma_{\text{read}}^2 + m/K}$ 可积出闭式

$$c(m) = \int_0^m \frac{dm'}{\Delta(m')} = 2Kr^* \left[\sqrt{\sigma_{\text{read}}^2 + \frac{m}{K}} - \sigma_{\text{read}} \right],$$

即码值分配函数 $c(m)$ （与第 IX-A1 节表 IV 的校正量 c 同名不同义）是 $\sqrt{\sigma_{\text{read}}^2 + m/K}$ 的仿射函数：近黑处读噪主导，曲线近似线性；亮部 shot noise 主导，曲线转为平方根。该式与自适应数值积分在机器精度内一致（ m 自 1 至 65535 六点的最大相对残差为 2×10^{-14} ）。等价地， $dc/dm \cdot \sigma_t \equiv r^*$ ，即该曲线就是把噪声标准差稳定到 r^* 的方差稳定变换。此处的 r^* 即第 IV-A 节的 $r = \sigma_t/\Delta$ 推广到全电平；第 V 至 X 节的数值工作点固定取近黑读噪 4.729 DN16，在亮部与之不同。由该式，按 $\Delta = \sigma_t/r^*$ 设计的表满足 $P(m)/\sigma_t(m) = b/r^*$ 与电平无关，故下一小节的条件是全电平判据。该恒等式设 b 在全电平取同一值且 $\bar{\Delta}$ 取连续值；整数化后 P/σ_t 在每段内随电平下降，取段底为最紧点。本小节的判据 $\Delta(m) \leq \sigma_t(m)/r^*$ 是直接量化口径，对应压扩发生在连续输入侧；同一曲线若以表的形式作用在已量化的整数码流上，控制量应换成下一小节的 P 。

该形式并非新结果，此处给出闭式只为把它与前文判据的关系写清楚。该形式与泊松叠加高斯情形的广义 Anscombe 变换同形 [36]；FITS 图像压缩工具 fpack 的量化参数即本节的 r^* ，其手册给出的噪声增量与 $\sqrt{1 + 1/(12r^{*2})} - 1$ 逐位一致 [37]；相机侧的有损 RAW 压缩同样把压扩表作用在整数码上，其逆表在 DNG 规范中由 LinearizationTable 承载 [38]；本文不对具体厂商的曲线形状作断言。

由 $\Delta \leq \sigma_t/r^*$ ，该闭式给出的是所需码数的下界。以第 IV-B 节的参数为例， $c(65535)$ 分别为 263.3、539.4、1699.0，即覆盖 16-bit 满量程至少需 264、540、1700 个步长（8.04、9.08、10.73 bit），对应 $r^* = 0.62、1.27、4$ 。三个取值分别取自第 VII 节的直接量化二阶阈值、第 IX 节两级链路的二阶阈值与 fpack 手册的常用量化级，此处只作码数量级的对照。

B. 压扩表作为两级链路

压扩表作用在已量化的整数码流上，本身即第 IX 节的两级链路 $T(Q_1(x))$ 。设表把整数码按组宽序列

$\{w_i\}$ 分组、每组以其中中心重建，则复合误差 $g(x) = T(Q_1(x)) - x$ 的周期为一个重复单元所覆盖的输入码数 P （与第 III-C 节的像素数同名不同义）； $\bar{\Delta}$ 只在 $P = b\bar{\Delta}$ 这一关系中出现，本身不进入阻尼。由第 IX-C1 节的高斯卷积阻尼，第 k 个相位谐波带因子 $\exp[-\sigma^2(2\pi k/P)^2/2]$ ，故基波（ $k=1$ ）进入指数的比值是

$$r_{\text{eff}} = \frac{\sigma}{P} = \frac{\bar{\Delta}}{P} r.$$

ties-to-even 是该式的特例：其组宽为 5、3 交替， $P = 8 = 2\bar{\Delta}$ ，故 $r_{\text{eff}} = r/2$ ，阈值随之约翻倍（实测 1.92 与 2.05，见第 IX-C1 节）。

此处的 P 指最小周期。 M_2 的第 k 个谐波是两个因子之积：上式的阻尼随 k 下降，而由组宽序列决定的前因子随 k 总体上升；对组宽接近相等的序列，它在组数 b 附近达峰（一般序列既不单调也不在 b 处达峰，如 $\{3, 3, 3, 8\}$ 的前因子自 $k=1$ 起为 19.8、45.5、16.2、34.9，在 $k \leq P/2$ 内峰在 $k=6$ 而非 $b=4$ ；该处阻尼已极小，此例只用以说明前因子的峰位与单调性都不必如此）；主导 A_2 的是该乘积取极值的 k ，未必是 $k=1$ 。以 $\{4^{\times 9}, 5\}$ （ $P=41$ ）为例，前因子（以 DN16² 计，即 M_2 的谐波幅度除以阻尼）自 $k=1$ 至 $k=10$ 依次为 0.018、0.60、1.51、2.68、4.04、...、82.4，而基波的阻尼 $\exp[-\sigma^2(2\pi/P)^2/2] = 0.769$ 几乎不衰减；基波的谐波幅度只占各阶幅度之和的 3.3%，是前因子小而非阻尼强所致，主导者为 $k=2$ 。故 $r_{\text{eff}} = \sigma/P$ 只刻画阻尼的那一半，在前因子随 P 显著变化时不足以预测 A_2 的量级。表 VII 前四行（ $P \leq 21$ ）基波占各阶幅度之和的 81% 至 100%，设计条件所处的 $P \leq 7.6$ 更在其内，基波主导成立。 r_{eff} 只控制阻尼的指数，谐波的前因子在给定 σ 下由组宽序列与 d_i 决定（该前因子含 $2\sigma^2(i2\pi k/P)\hat{g}_k$ 的交叉项，故亦随 σ 变，下文的符号规则须在判据给出的 σ 处评估），故不能把 r_{eff} 代回直接量化的解析式外推。该前因子有闭式。记一个周期内的判决边界为 e_i 、重建值为 R_i （ $e_{i+b} = e_i + P$ 、 $R_{i+b} = R_i + P$ ），跳变 $J_i = R_{i+1} - R_i$ ， $\alpha_i = e_i - R_i$ 、 $\beta_i = R_{i+1} - e_i$ ， $\omega_k = 2\pi k/P$ 。 g 在每个单元上是 $R_i - x$ ，对 $\hat{g}_k$ 与 $\hat{g}_k^2$ 分部积分时纯指数的原函数项在整周期上逐项相消，只剩边界项：

$$\hat{g}_k = \frac{1}{i\omega_k P} \sum_i J_i e^{-i\omega_k e_i},$$

$$\hat{g}_k^2 = \frac{1}{P} \sum_i e^{-i\omega_k e_i} \left[\frac{2J_i}{\omega_k^2} + i \frac{\alpha_i^2 - \beta_i^2}{\omega_k} \right].$$

代回第 IX-C1 节的阻尼即得 M_2 的完整谐波形式；其 $k = 0$ 项恰为下文的 E_q ，可作自洽检验（数值上两者相差 10^{-14} ）。该闭式与第 IX-A 节的离散高斯求和在所试序列上逐位一致，二者互为独立实现。大 σ 下 $2\sigma^2 J_i$ 一项主导，故 M_2 与 M_1 的相位调制由同一个结构因子 $S_k = \sum_i J_i e^{-i\omega_k e_i}$ 控制。 $\bar{\Delta} = 4$ 、 $P = 8$ 的三族（等宽 4 配 $d = (\pm\frac{1}{2}, \mp\frac{1}{2})$ 、5、3 交替、7、1 交替）的 $|S_1|$ 依次为 2.00、3.06、7.39，与其 A_2 的 1.82%、2.60%、6.50% 同序。 S_1 只是大 σ 的主项而非一般判据：在 $\{4, 4, 4, 4, 7\}$ 上 $|S_1| = 0.24$ 的解给出 0.77 倍而 $|S_1| = 0.84$ 的解给出 0.53 倍，序反。

以下设各组 $w_i \geq 1$ 且 $R_0 < R_1 < \dots < R_{b-1} < R_0 + P$ （跨周期亦严格单调）。互异保证相邻组不合并，否则 b 不等于真实组数、 $\bar{\Delta} = P/b$ 与组宽序列不对应；严格单调另由表须保序可逆给出，本节及第 X-C 节的全部枚举均沿用这一条。若 $\bar{\Delta} = W + a/b$ （最简分数），则组宽尽量相等的序列由 b 个组构成，其中 a 个宽 $W + 1$ ，覆盖 $P = b\bar{\Delta}$ 个输入码，于是 $r_{\text{eff}} = r/b$ 。表 VII 给出固定 $\sigma = 4.729 \text{ DN16}$ 时的结果。

平均组宽由 4.00 改为 4.25 仅粗 6.25%，而 A_2 由 7.1×10^{-11} 升至 0.327，相差 4.6×10^9 倍。其中量化粗化本身只解释约 21 倍： r 由 1.182 降至 1.113，直接量化解析式 A_2 相应放大 20.7 倍（指数因子 23.3 倍、前因子 0.89 倍）；余下约 2×10^8 倍来自组宽序列由 $\{4\}$ 变为 $\{4, 4, 4, 5\}$ ，而这不能单归于重复长度：以同一 $\bar{\Delta} = 4.25$ 的直接量化器为中间参照，该变化使基波阻尼放松 8.9×10^9 倍（由 P 决定），同时使基波前因子反向压回 40 倍（由组宽序列与 d_i 决定，不由 P 决定）， $\bar{\Delta}^2$ 归一在此步不变，二者相抵后即该余量。表中 A_2 自 4.25 至 4.10 反而下降，来自前因子。非单调自 $\bar{\Delta} = 4.25$ 到 4.20（ P 由 17 到 21）即已出现，而该两行基波仍占 96% 与 81%：其基波阻尼由 0.217 放松到 0.368， A_2 却由 0.327 降到 0.277，只能由前因子同步下降解释。该步 $\bar{\Delta}$ 由 4.25 变为 4.20，故须按本节口径除以 $\bar{\Delta}^2$ 归一：前因子的生下降倍数为 2.06（即比值 $1/2.06$ ），归一贡献 1.024，归一后的下降倍数为 2.01。以阻尼比 1.693 除以该下降倍数得 0.843，而实测的 A_2 比为 0.846，残差 0.3% 来自 $k \geq 2$ 谐波（ A_2 是各阶合成后的相位极差，只有仅取基波时该关系才严格成立）。到 $P = 41$ 时基波前因子（未归一）已降至 $P = 17$ 的 $1/127$ ，按 $\bar{\Delta}^2$ 归一后为 $1/118$ ；但该处主导谐波已移至 $k = 2$ ， A_2 的量级由 $k = 2$ 的前因子 0.60 与阻尼 0.350

表 VII

平均组宽、重复长度与相位指标（固定 $\sigma = 4.729 \text{ DN16}$ ）。各行均以组中心重建，用于演示 P 与 $\bar{\Delta}$ 的分工，不作设计菜单用：宽度为偶数的组其中心为半整数（整数码上的这一奇偶对应见 [5] 第 4.2 节），故除 TIES-TO-EVEN 一行外，各行按表中所列的中心重建在第 X-C 节的约束下不可实现。其中 $\{4\}$ 与 $\{4, 5\}$ 改用 $d \neq 0$ 亦无解；其余三行存在整数重建零直流的实现： $\{4, 4, 4, 5\}$ 与 $\{4^{\times 9}, 5\}$ 的 A_2 分别劣化 7.42 与 6.35 倍，两者均为全空间最优。该约束集本身有限，无须对 d_i 设界：以 $g_i = R_i - R_0$ 参数化后 $0 < g_1 < \dots < g_{b-1} < P$ 而 R_0 由零直流唯一解出，故合法构造至多 $\binom{P-1}{b-1}$ 个，其中约 $1/P$ 满足整除；两行分别为 32 与 6669240 个，均已穷举，而 $\{4, 4, 4, 4, 5\}$ 因宽 4 的组数为偶，存在 $\max_i |d_i| = \frac{1}{2}$ 的解（另两行则被迫取到 $|d_i| = 2$ ）；这 6 个解中只有 $d = (+\frac{1}{2}, -\frac{1}{2}, +\frac{1}{2}, -\frac{1}{2}, 0)$ 使 A_2 改善（为 $d = 0$ 值的 0.83 倍），其余五个劣化 2.99 至 8.18 倍（其中最小者即该解的整体反号），全部 231 个合法构造的中位数为 $d = 0$ 值的 28 倍。故偶数个宽 4 组只保证了 $\pm\frac{1}{2}$ 解的可行性；该族内 S_1 定序：六个 $\max_i |d_i| = \frac{1}{2}$ 解的 $|S_1|$ 依次为 0.14、0.79、1.23、1.23、1.41、2.06，与上列比值完全同序，唯一改善者正是唯一把 $|S_1|$ 压到 $d = 0$ 值以下的那个；但该定序不推广——在同族相邻序列上该现象并不稳定： $\{4, 4, 4, 4, 3\}$ 的两个 $\pm\frac{1}{2}$ 交替解均劣化（1.59 与 3.38 倍），而 $\{4, 4, 4, 4, 7\}$ 的非交替解 $(+\frac{1}{2}, +\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, 0)$ 亦改善（0.77 倍）。

$\bar{\Delta}$	组宽序列	b	P	A_1	A_2
4.00	4	1	4	3.3×10^{-13}	7.1×10^{-11}
4.50	4, 5	2	9	4.8×10^{-4}	3.96×10^{-2}
4.25	4, 4, 4, 5	4	17	7.9×10^{-3}	3.27×10^{-1}
4.20	4, 4, 4, 4, 5	5	21	9.2×10^{-3}	2.77×10^{-1}
4.10	$4^{\times 9}, 5$	10	41	9.6×10^{-3}	2.43×10^{-1}
4.00	5, 3 (ties-to-even)	2	8	2.5×10^{-4}	2.60×10^{-2}

决定。故 A_2 的量级由前因子与阻尼共同决定，二者都随组宽序列变化。

由 $r_{\text{eff}} = r/b$ 可得压扩表的设计条件：以相位结构落在容差 ε 之内为目标，取

$$b \leq \frac{r}{r_\varepsilon},$$

其中 r_ε 为第 VII 节的相应阈值。以第 IV-B 节的工作点 $r = 1.18$ 与 $\varepsilon = 1\%$ 的二阶阈值 $r_{2,\varepsilon} = 0.620$ 计，得 $b \leq 1.9$ （该数只对 $\bar{\Delta} = 4$ 成立，因 $r = \sigma/\bar{\Delta}$ 随 $\bar{\Delta}$ 变；不含 $\bar{\Delta}$ 的等价形式是 $P \leq \sigma/r_\varepsilon$ ），故在该族内只有整数平均组宽可用；表 VII 与之自洽： $b = 2$ 的 $\bar{\Delta} = 4.50$ 已给出 $A_2 = 4.0\%$ （按 E_q 归一 3.8%），为容差的四倍。

b 恒为一个周期内的组数，故 $r_{\text{eff}} = r/b$ 对任意序列成立（ b 取最小周期内的组数，否则如把 ties-to-even 写成 $\{5, 3, 5, 3\}$ 会得到错误的 $r/4$ ）；但 b 不由 $\bar{\Delta}$ 唯一决定，只有对上述组宽尽量相等的序列， b 才等于 $\bar{\Delta}$ 最简分数的分母。一般序列应直接以 P 表述：

$$P \leq \frac{\sigma}{r_\varepsilon},$$

同一工作点下为 $P \leq 7.6$ 个输入码。该式把 r_{eff} 与直接量化的阈值相比，而前因子并不随之变换，故该式是量级




图 22. 阻尼与 A_2 对最小重复长度 P 的不同走向 ($\sigma = 4.729 \text{ DN16}$, A_2 按本节口径以 $\bar{\Delta}^2/12$ 归一)。灰色点线为基波阻尼, 随 P 单调上升; 橙线为表 VII 的等宽近似族, A_2 自 $P = 9$ 的 3.96% 升到 $P = 17$ 的 32.7% 后回落至 $P = 21$ 的 27.7% 与 $P = 41$ 的 24.3%, 即不随阻尼单调。同一 P 上的纵向散布说明 P 不足以决定 A_2 : $P = 17$ 、 $b = 4$ ($\bar{\Delta} = 4.25$) 的 120 条本原序列自 10.0% 至 556%, 跨 55 倍。等宽器 $\{4\}$ 的 $A_2 = 7.1 \times 10^{-9}\%$ 低于纵轴下端九个量级, 未入图。

判据而非严格的界。其偏差在等宽序列 ($b = 1$) 上恒为零, 因为此时复合器精确退化为直接 Q_w 。该偏差只取决于组宽序列的形状: $A_2(\sigma; \lambda\{w_i\}) = A_2(\sigma/\lambda; \{w_i\})$ (各 d_i 须同步乘 λ , 否则等式不成立; λ 取正整数, 使 $\lambda\{w_i\}$ 仍为整数组宽; 该恒等式源于复合映射等价于连续输入上的非均匀量化器, 内层 Q_1 已被吸收), 故判据给出的 $\sigma_{\text{crit}} = Pr_\epsilon$ 与实测阈值同步缩放, 偏差对整体标度不变, 不能由 $\bar{\Delta}$ 的取值范围加以约束。其符号亦不能由单一的不均匀度排序——同为 $P = 17$ 、 $b = 4$ 时, $\{3, 5, 4, 5\}$ 偏 +21.6% 而更不均匀的 $\{3, 3, 3, 8\}$ 偏 -8.3%; 基波前因子与 $\bar{\Delta}^2$ 之比越小, 判据越保守; 该比值在序列接近一个更短周期时趋于零, 下文的 $\{1, 3, 2, 3, 2, 3, 2, 3\}$ 即属此类 (偏保守逾一倍)。本文不给该偏差的一般上界。在判据给出的 σ 处基波阻尼恒为 $e^{-2\pi^2 r_\epsilon^2}$ 且高次谐波已被压尽, 故偏差由基波前因子与 $\bar{\Delta}^2$ 之比决定: 就二阶指标而言, 判据偏保守当且仅当该比值小于 $4r_\epsilon^2 + 1/\pi^2$ 。只看前因子而不除 $\bar{\Delta}^2$ 会给出错误的排序。以下就二阶指标而言 (同一序列上一阶可反向: ties-to-even 的一阶判据给 $r \geq 0.837$ 而精确值为 0.804, 偏严): 宽窄反差大而不接近更短周期的短序列偏乐观——对 ties-to-even 该式给出 $r \geq 1.240$, 而第 IX 节离散和的精确阈值为 1.273, 在 $r = 1.240$ 处实测 $A_2 = 1.44\%$; 多等宽加一个异宽的长序列则偏保守, $\bar{\Delta} = 4.10$ 一行高估所需 σ 约 16% (判据要求 25.413, 实测 21.90)。以 1% 为目标时,

表中各序列实际达到的 A_2 落在 0.19% 至 1.44% 之间。

该式只以 P 为变量, 因此不是充分刻画; 由下文 $\{1, 3, 2, 3, 2, 3, 2, 3\}$ ($P = 19$ 而 $A_2 = 0.82\%$) 可见它也不是必要条件。其作为刻画的不充分则见于: 固定 $P = 17$ 且 $\bar{\Delta} = 4.25$ 时, $\{3, 5, 4, 5\}$ 、 $\{4, 4, 4, 5\}$ 、 $\{3, 3, 3, 8\}$ 的 A_2 分别为 0.100、0.327、2.859, 跨 28.5 倍; 这三者的 $P = 17$ 均不通过判据, 故它们证的是 P 不足以决定 A_2 , 而非判据本身失效——判据作为充分条件的反例, 在 $P \leq 7$ 的全部 40 个本原旋转类 (它们都通过判据, 各组以其中中心重建) 中共三条: $\{1, 1, 1, 4\}$ 、 $\{1, 1, 5\}$ 、 $\{1, 1, 1, 1, 3\}$, A_2 分别为 1.77%、1.64%、1.28%。这三条与归一口径有关。本节用到两种归一, 分工如下。其一, A_2 的表列值与跨序列比较一律以 $\bar{\Delta}^2/12$ 归一、 A_1 一律以 $\bar{\Delta}$ 归一 (后者与第 IX-C1 节以 Δ_{14} 归一的口径不同); 固定 $\bar{\Delta}$ 时它是合用的无量纲标度, 下文前因子的分解即建立在它上面。其二, 凡 A_2 与容差 ϵ 的比较, 分母须取被并入读噪的那一项, 即下式的相位平均量化能量 $E_q = \sum_i (w_i^3/12 + w_i d_i^2) / \sum_i w_i$ ——第 VII 节正是以「该项相对自身的相位调制半幅」定义 A_2 , 并据此把 ϵ 解释为所报 DR 损失的相对记账误差; 对压扩表 M_2 的相位平均为 $\sigma^2 + E_q$ 而非 $\sigma^2 + \bar{\Delta}^2/12$, 故只有后一口径才承载 ϵ 的含义。二者之比 $E_q/(\bar{\Delta}^2/12)$ 在组宽悬殊时可达三倍以上 ($\{1, 1, 1, 4\}$ 为 3.13 倍), 在表 VII 各行则为 1.00 至 1.19——首行的等宽器恰为 1,

因为 $b = 1$ 时 $E_q = \bar{\Delta}^2/12$ 恒等。第 VII 节的阈值 r_ε 正是在等宽器上定出的，故它与由它导出的 $P \leq \sigma/r_\varepsilon$ 、 $\sigma/r_\varepsilon = 7.63$ 、 $\sigma/(2r_\varepsilon) = 3.81$ 都与归一口径无关；本节其余各处引述的 A_2 数值若未另行标注，均为 $\bar{\Delta}^2/12$ 口径。上述三条反例即属前者：改以 E_q 归一后分别为 0.57%、0.49%、0.57%， $P \leq 7$ 内不再有反例。判据的不充分性本身在该口径下仍在： $\{1, 1, 1, 4\}$ 的实测阈值为 $\sigma = 4.558$ ，高于判据给出的 4.339，只是本文工作点 $\sigma = 4.729$ 在两者之上。其适用域亦须限定在 $\bar{\Delta}$ 与 σ/r_ε 同量级的范围内（本文工作点 $\bar{\Delta} \approx 4$ ）：偏乐观一侧（判据通过而 A_2 超出容差）的误判集中在小 $\bar{\Delta}$ ，由判据自身的预算给出： P 为输入码的计数故取整数， $P \leq \sigma/r_\varepsilon = 7.63$ 即 $P \leq 7$ ，于是 $b \geq 2$ 时 $\bar{\Delta} = P/b \leq 3.5$ （由 $\{3, 4\}$ 、 $\{2, 5\}$ 、 $\{1, 6\}$ 取到），而 $\bar{\Delta} \geq 4$ 只剩 $b = 1$ 的等宽器——上文已述该偏差在等宽序列上恒为零。偏保守一侧的 $P > \sigma/r_\varepsilon$ 不受该预算约束，其误判落在小 $\bar{\Delta}$ 是数值观察：所试误判全部出现在 $\bar{\Delta} \leq 2.7$ 。归一差本身不足以给 A_2 排序（上述 40 个本原类上二者的 Spearman 相关为 0.57： $\{1, 1, 4\}$ 的归一差 2.75 而 A_2 仅 0.07%， $\{1, 1, 1, 1, 3\}$ 的归一差更小的 2.26 却是反例），且它是尺度不变的量（各组以中心重建时为 $b^2 \sum_i w_i^3 / (\sum_i w_i)^3$ ），不由 $\bar{\Delta}$ 的大小决定。该式对表 VII 全部六行给出与 A_2 一致的判定，包括 b 不由 $\bar{\Delta}$ 决定的 ties-to-even 行（其 $b = 2$ ）：其平均组宽为整数 4，但 5、3 交替使 $P = 8$ 恰在界外，对应第 IX 节的 $A_2 = 2.60\%$ 。反之，若 $\bar{\Delta}$ 非整数，则一个周期至少含两个组， $P \geq 2\bar{\Delta}$ ；当 $\bar{\Delta} > \sigma/(2r_\varepsilon) = 3.81$ 时即有 $P > 7.6$ 。故在 $\bar{\Delta} \gtrsim 3.8$ 的一族内（含本文工作点 $\bar{\Delta} = 4$ ），整数平均组宽就该判据而言是必要条件而非充分条件；对 A_2 本身则由数值支持——在 $b \leq 5$ 、组宽 ≤ 12 且 $3.81 < \bar{\Delta} \leq 12$ 的全部 41 719 条旋转不等价的非整数序列上，实测最小 A_2 为 3.96%（ $\{4, 5\}$ ），本文不给严格证明；更小的 $\bar{\Delta}$ 不受此限，例如 $\{3, 4\}$ 的 $\bar{\Delta} = 3.5$ 非整数而 $P = 7$ ，实测 $A_2 = 0.24\%$ （按 E_q 归一 0.23%），在容差之内。该例之所以成立是因为 $P = 7$ 仍在界内，而非因 $\bar{\Delta}$ 较小：其邻域内 $\{3, 4, 4\}$ （ $\bar{\Delta} = 11/3$ ， $P = 11$ ）、 $\{3, 3, 4\}$ （ $P = 10$ ）、 $\{3, 4, 4, 4\}$ （ $P = 15$ ）的 A_2 分别为 10.6%、9.5% 与 20.0%（按 E_q 归一为 10.1%、9.0% 与 19.2%），均远超容差。

该条件在相位平均量化能量的框架内不可见：由下式，后者只依赖组宽的多重集且变化平缓（ $\{5, 3\}$ 相对 $\{4, 4\}$ 仅高 18.75%），无法反映 P 由 4 变为 8 所对应

的 A_2 的 10^8 量级差异。

组宽不等还带来额外的相位平均量化能量。设一个周期内组宽为 w_i 、各以自身中心重建，则

$$\overline{M_2^q} = \frac{\sum_i w_i^3}{12 \sum_i w_i}.$$

取 $\{4, 4\}$ 得 16/12，取 $\{5, 3\}$ 得 19/12，与第 IX-C3 节一致。若重建值偏离组中心 d_i ，该式推广为 $\sum_i (w_i^3/12 + w_i d_i^2) / \sum_i w_i$ 。该式是 Bennett 非均匀量化失真积分在相位均匀分布下的特例 [13]。由幂平均不等式，固定 $\sum_i w_i$ 与组数（即固定 $\bar{\Delta}$ ）时， $\sum_i w_i^3$ 在各 w_i 相等时取最小，故等宽组是该式的下确界；ties-to-even 的 5、3 交替比同均值的 4、4 多 18.75%。 $\sum_i w_i^3$ 只取决于组宽的多重集而与其排列无关，故该式不能用于选择排列；排列确实影响相位指标，且使 A_1 最小的排布未必使 A_2 最小。

C. 整数重建下的可实现性

上一小节把表视为把整数码分组、每组以其中心重建。实际解压表输出整数（DNG 规范的 LinearizationTable 即为整数数组 [38]），故重建值 $R_i \in \mathbb{Z}$ 。本小节另设一条前提：不允许第 IX-A1 节那样的小数固定校正，即要求相位平均误差均值为零。该前提对应第 IX-A 节所述「无法规范小数黑电平」的情形；若允许小数校正，则本小节的否定结论不成立——half-up 本身即一张 $\bar{\Delta} = 4$ 的整数输出表（宽 4 的组以中心加 $\frac{1}{2}$ 重建，重建值为整数），其 $A_2 = 7.1 \times 10^{-11}$ ，代价正是那个 $+\frac{1}{2}$ DN16 的常量偏置。记 c_i 为第 i 组所含整数码的中心、 $d_i = R_i - c_i$ ，则相位平均误差均值为 $\frac{1}{P} \sum_i w_i d_i$ ，零黑电平偏移即要求

$$\sum_i w_i d_i = 0.$$

组宽 w_i 为奇数时 c_i 是整数，可取 $d_i = 0$ ；为偶数时 c_i 是半整数，故 $d_i \in \mathbb{Z} + \frac{1}{2}$ ， $|d_i| \geq \frac{1}{2}$ 。偶数组宽并不因此被排除：取 $\{4, 4\}$ 与 $d = (+\frac{1}{2}, -\frac{1}{2})$ 即同时满足整数重建与零直流。

真正起限制作用的是上一小节的条件对组数的约束。当 $\bar{\Delta} > \sigma/(2r_\varepsilon)$ 时， $P = b\bar{\Delta} \leq \sigma/r_\varepsilon$ 迫使 $b = 1$ ，零直流条件退化为 $w_1 d_1 = 0$ ，故 $d_1 = 0$ ，组宽必须为奇数。于是在第 IV-B 节的工作点（ $\sigma/(2r_\varepsilon) = 3.81$ 、 $\sigma/r_\varepsilon = 7.63$ ），可用的平均组宽只有该区间内的奇整数 5 与 7，其 A_2 分别为 9.5×10^{-7} 与 2.8×10^{-3} 。

$\bar{\Delta} = 4$ 在该约束下不可实现。 $b = 1$ 需要单个宽度为 4 的组, 其中心是半整数; $b \geq 2$ 则 $P \geq 8 > 7.63$ 。若组宽全取奇数, 由 $P = \sum_i w_i \equiv b \pmod{2}$ 与 $P = 4b$ 为偶数, 同样得 b 为偶、 $P \geq 8$ 。两条路径都给出 $\min P = 8$ 。但 A_2 对 P 并不单调 (表 VII 自 $P = 17$ 至 41 即为反例), 故仅由 $\min P = 8 > 7.63$ 推不出不可达; 该结论须由直接穷举给出。对 $b \leq 7$ ($P \leq 28$) 的全部整数重建零直流构造穷举, 并对组外重建作放宽, 该范围内的最小值为 $P = 8$ 处的 1.82% (在 $b = 2, 4, 6$ 上取到; 下文 $b = 8$ 的全空间最小值同为该构造的重复; 按 E_q 归一为 1.53%); 其中 $b = 7$ 一档为 42288 个旋转最小的组宽序列上的 4.47×10^8 个构造 (按有序序列计 3.13×10^9), 其最小 $A_2 = 21.4\%$ 。 $b = 8$ ($P = 32$) 亦已在全空间穷举, 无须对 d_i 设界: 以 g_i 参数化后合法构造按有序序列计 2.1609×10^{11} 个——与不经枚举的组合估计 $\binom{P-1}{b-1}^2 / P = 2.1608 \times 10^{11}$ 相差 0.005%——按旋转等价类计 2.7012×10^{10} 个。二者之比为 7.9999995: 最小周期短于 32 的构造仅 13596 个 (占 6×10^{-8}), 落在 3402 个非满轨道上, 故轨道几乎全为满轨道 (该计数即 Burnside 中的 $\text{Fix}(4)$: C_8 的每个非平凡子群都含 $\langle 4 \rangle$, 故 $\bigcup_{k \neq 0} \text{Fix}(k) = \text{Fix}(4)$ 。权重和 $\sum_{k \neq 0} \text{Fix}(k)$ 则把每个构造按 $|\text{Stab}| - 1$ 重计: 周期恰为 4 个组 (16 码) 的 13584 个各计一次、周期恰为 2 个组 (8 码) 的 12 个各计三次, 故 $13620 = 13596 + 2 \times 12$, 不是构造计数)。其中最小周期确为 32 者的最小 $A_2 = 7.39\%$, 由 $\{1, 4, 3, 7, 7, 3, 4, 3\}$ 、 $d = (0, \frac{1}{2}, -1, 0, 0, 1, -\frac{1}{2}, 0)$ 达到; 全空间的最小值则为 1.82%, 由 $P = 8$ 解的四次重复给出, 与上文一致。这一重合有结构上的理由: $\bar{\Delta} = 4$ 时最小周期 P' 既整除 $P = 32$, 又因整个构造是最小周期单元的重复而满足 $P'/b' = P/b = 4$, 故 $P' = 4b'$ 且 $4b' \mid 32$, 即 $b' \in \{1, 2, 4, 8\}$ 。于是 $b = 8$ 中最小周期短于 32 的构造都是 $b' \in \{2, 4\}$ 解的重复 ($b' = 1$ 如上无解), 截取一个最小周期, 所得 b' 构造仍合法——零直流由 $\sum_{\text{全周期}} w_i d_i = (b/b') \sum_{\text{单周期}} w_i d_i = 0$ 给出, 严格单调与整数重建逐项继承; 而重复不改变 $M_2(s)$ 本身, 故 $\bar{\Delta}$ 、相位半极差与 E_q 三者都与被重复者相同, 两种归一下的 A_2 亦相同。因此 $b = 8$ 一档相对 $b \leq 7$ 新增的只有最小周期恰为 32 的子集。 $b > 8$ 未枚举。对 $b > 8$ 本文只给量级论证: $P \geq 32$ 时基波阻尼 $\exp[-\sigma^2(2\pi/P)^2/2] \geq 0.649$ 已近饱和, 要把 A_2 压到 1% 以下需基波前因子比 $P = 8$ 处再低约三个量级。作为旁证: 上述 $P = 32$ 构造的 A_2 由 $k = 1$ 至 4 四阶

共同构成 (按 $\bar{\Delta}^2/12$ 归一分别约 3.4%、3.8%、1.8%、3.7%), 要落到 1% 需同时压掉这四阶。此为启发式, 且该说法与归一口径有关: 按 E_q 归一四阶为 1.77%、1.96%、0.91%、1.92%, 其中 $k = 3$ 本就在容差之内。换归一后须重新取极小而不能沿用原取到者: 由幂平均不等式 $E_q \geq \bar{\Delta}^2/12$ 逐点成立, 原取到者在新口径下的读数只是极小的上界, 而取到者确会移动 (4Z 约束下 $b = 4$ 、 $\max_i |\delta_i| = \frac{5}{2}$ 一档即如此)。按 E_q 逐档重新取极小的结果: $b \leq 7$ 各档为 1.53%、45.4%、1.53%、16.1%、1.53%、10.9%, 全局极小 1.53% 在 $b = 2, 4, 6$ 上取到且取到者不变, 各档均超出 1%。 $b = 7$ 一档的取到者确随口径移动: $\bar{\Delta}^2/12$ 口径取到 $\{2, 2, 4, 5, 5, 5, 5\}$ 的 21.4%, E_q 口径取到 $\{1, 7, 1, 7, 3, 4, 5\}$ 的 10.9%, 故上述重取是必要的而非形式的。故 $\bar{\Delta} = 4$ 的排除在两种归一下都由 $b \leq 7$ 的穷举给出; 下文 $b = 8$ 一档的数值按 $\bar{\Delta}^2/12$ 归一报, 它相对 $b \leq 7$ 新增的只有最小周期恰为 32 的子集, 不参与该排除。该重取的做法与上文的枚举相同, 只枚举旋转最小的组宽序列——旋转组宽序列等于把整张表沿码轴平移, $M_2(s)$ 只作平移而 $\bar{\Delta}$ 、相位半极差与 E_q 均不变, 故极小值不受影响; 并按下述两条严格界剪枝: 记 M_2 的非零阶谐波系数为 c_k , 在 $k = 1$ 的极值点上取其余各阶的最坏情形得 $H \geq 2|c_1| - 2\sum_{k \geq 2} |c_k|$, 而三角不等式给 $H \leq 2\sum_k |c_k|$, 只有下界仍可能刷新当前最优的构造才需重建相位波形; $b = 7$ 一档实际需要重建的占 3.9%。故在上述前提下, $b \leq 8$ 各档的 1% 容差在 $\bar{\Delta} = 4$ 上已由枚举排除, $b > 8$ 只有上述量级论证; 在此意义下第 IX 节的 $A_2 = 2.60\%$ 并非规则选择不当所致。

穷举 $\bar{\Delta} = 4$ 、 $P = 8$ 的全部整数重建零直流构造, A_2 最小者是等宽 4 配交替偏移 $d = (\pm\frac{1}{2}, \mp\frac{1}{2})$, 给出 $A_2 = 1.82\%$; ties-to-even 的 5、3 交替给 2.60%。两者都在容差之外, 但前者的 A_2 低 1.4 倍。两者的相位平均量化能量同为 $19/12 \text{ DN}16^2$ (前者由上式的推广形式给出, $2 \times 4^3/12 + 2 \times 4 \times (1/2)^2$ 除以 8), 近黑 DR 损失同为 0.0467 stop; 1.4 倍的差别只在相位调制上。第 IX 节的 $16 \rightarrow 14$ bit 情形另有一层约束: 该节以固定标度 4 解释 14-bit 码, 即不经 LinearizationTable 重建, 故重建值须落在 4Z 上, 等宽 4 配交替偏移不满足该约束。若允许查表重建, 该构造即一张可用的 $16 \rightarrow 14$ 表, 码率与 ties-to-even 相同。该约束下的构造可用判决边界重新参数化。该参数化不免去逐 b 的枚举, 其作用有三: 把零直流畅化为一个线性条件; 由此给

出 b 必为偶的理由；并给出重建偏移的显式界，使枚举范围可陈述。以下沿用第 X-B 节声明的重建值随码严格递增；它是解压表的常规要求，而本小节此前列出的约束 ($R_i \in \mathbb{Z}$ 、零直流、 $R_i \in 4\mathbb{Z}$) 并不蕴含它。在该前提下重建值的间距恒为 4: $R_i \in 4\mathbb{Z}$ 且严格递增，而一个周期内 ($R_{i+b} = R_i + P$) b 个正的 4 的倍数之和为 $P = 4b$ ，故每个相邻间距恰为 4。设第 i 组与第 $i+1$ 组之间的判决边界为 e_i ，令 $\delta_i = e_i - (R_i + 2)$ (下标按周期回卷， $\delta_0 = \delta_b$)，则

$$w_i = 4 + \delta_i - \delta_{i-1}, \quad d_i = -\frac{1}{2}(\delta_i + \delta_{i-1}),$$

而 $\sum_i w_i d_i = -4 \sum_i \delta_i - \frac{1}{2} \sum_i (\delta_i^2 - \delta_{i-1}^2) = -4 \sum_i \delta_i$ (两处均用到周期性: $\sum_i \delta_{i-1} = \sum_i \delta_i$ ，且平方项逐项相消)，故零直流等价于 $\sum_i \delta_i = 0$ 。又组宽须为正， $w_i = 4 + \delta_i - \delta_{i-1} \geq 1$ ，即 $\delta_i - \delta_{i-1} \geq -3$ 。配合 $\sum_i \delta_i = 0$ 即得显式界 $\max_i |\delta_i| \leq \frac{3}{2}(b-1)$ ：记 $M = \max_i \delta_i$ ，自最大者起每步至多降 3，故 $0 = \sum_i \delta_i \geq bM - \frac{3}{2}b(b-1)$ ，即 $M \leq \frac{3}{2}(b-1)$ ；由 $\delta_{i-1} \leq \delta_i + 3$ 对最小者作镜像论证得 $\min_i \delta_i \geq -\frac{3}{2}(b-1)$ 。该界可达，取等构型为 $w = (3b+1, 1, \dots, 1)$ (b 为偶时合法)。故 δ 的取值空间有限。输入码为整数、组界落在相邻整数码之间，给出 $e_i \in \mathbb{Z} + \frac{1}{2}$ ；本小节的整数重建前提给出 $R_i \in \mathbb{Z}$ 。两者合起来即 $\delta_i \in \mathbb{Z} + \frac{1}{2}$ ； b 个半奇整数之和为零要求 b 为偶，这解释了奇数 b 无解。在该参数化下 $\delta = (\pm\frac{1}{2}, \mp\frac{1}{2})$ 即 ties-to-even 的 5、3 交替 ($A_2 = 2.60\%$)， $\delta = (\pm\frac{3}{2}, \mp\frac{3}{2})$ 即 7、1 交替 ($A_2 = 6.495\%$)。 $b = 2, 4, 6, 8$ 在全部组宽序列上穷举 ($b = 8$ 一档为 2629575 个序列中的 328756 个合法构造，其 $\max_i |\delta_i|$ 上至 $21/2$)，最小 A_2 均为 2.60%、取到者均为 5、3 交替及其重复； $b = 10$ 在组宽全落于 $[1, 7]$ 的全部构造上穷举 (17538157 个序列中的 1753964 个)，结论不变。规律见于按 $\max_i |\delta_i|$ 的分层：该量为 $\frac{1}{2}$ 时最小 A_2 为 2.60% (即 5、3 交替)，为 $\frac{3}{2}$ 时为 6.495% (7、1 交替)，此后单调急升—— $b = 8$ 一档自 $\frac{5}{2}$ 起依次为 259%、530%、904%、1349%，至 $\frac{21}{2}$ 时达 5593%。 $b = 4$ 与 $b = 6$ 的分层在形态上相同——前两档数值一致，其后同样严格单调急升——但档数与数值随 b 变：共 $(3b-2)/2$ 档， $\frac{5}{2}$ 档在 $b = 4, 6, 8$ 上分别为 421%、235%、259%。该单调性是经验规律而非证明，且只在本节的 $\bar{\Delta}^2/12$ 归一下成立：改以 E_q 归一后 $b = 4$ 一档自 $\frac{1}{2}$ 起为 2.19%、2.42%、128%、149%、128%，峰在 $\frac{7}{2}$ 档而非末档，ties-to-even 相对 7、1 交替的优势亦由 2.49 倍降至 1.10 倍。 $b = 10$ 中组宽超出

$[1, 7]$ 者与 $b \geq 12$ 未穷举。故在所验范围内 ties-to-even 是该约束下的最优解。

D. 平滑曲线的直流偏置

平滑压扩曲线的平均组宽随信号连续变化，一般不落在整数上，按上述条件其相位结构不受指数压低。除此之外，该曲线还带有周期表所没有的直流分量。

对按组中心重建的量化器，误差在每个组内的积分为零，但其原函数在组内的均值为 $w^2/12$ 。对条件均值取高斯卷积后，该量的平滑部分给出

$$\bar{B} = \frac{1}{12} \frac{d(\Delta^2)}{dm}.$$

该常量偏置由 [5] 式 (23) 给出，其形式为 $\Delta'/6$ (Δ' 为每个码步上的步长增量，故 $\Delta' = \frac{1}{2} d(\Delta^2)/dm$ ，与上式相同)，并已指出它与输入分布无关、可由解码时的常量偏移吸收。本处重导它，用以与相位相干结构区分：两者在堆栈平均下的行为不同。对第 IV-B 节的噪声模型 $\Delta^2 = (\sigma_{\text{read}}^2 + m/K)/r^{*2}$ ，代入得

$$\bar{B} = \frac{1}{12Kr^{*2}} \text{ DN16},$$

与信号电平无关。该结论要求 σ_t^2 对 m 仿射，即噪声模型只含读噪与 shot noise 两项。数值上，取整分组、四舍五入分组与连续实数组界三种构造给出的结果与该式相符至约 3% (噪声按曲线自身的设计前提取 $\sigma_t(m) = \sqrt{\sigma_{\text{read}}^2 + m/K}$ ；若误按恒定读噪代入，则 σ/Δ 落到 0.02 至 0.07，相位平均不再发生，窗均值只是锯齿的残差，与该式无对应关系——所试点位的比值落在 -13.4 与 13.0 之间；两个端点来自不同的分组构造，而固定构造后仅平移评估窗即已跨越 -11.97 至 12.96 ，故该区间是所试点位的散布而非界；评估窗不少于二十个组，且要求 $d\Delta/dm \ll 1$ 、窗口远离曲线在 $m \rightarrow 0$ 处的端点)；以 $r^* = 1.18$ 计为 0.084 DN16。

该直流分量是确定性的常量偏移，不随堆栈平均衰减，也不属于第 IX 节所讨论的相位相干结构，在相位平均误差能量中同样不可见。由于它与电平无关，可被黑电平校正整体吸收——但该校正量为小数，正是第 X-C 节所排除的那一类，两处前提不同，不可互相援引；真正改变色调的是 σ_t^2 非仿射时它随电平变化的情形。

最后说明本节判据的适用范围。在 $\sigma/(2r_\epsilon) = 3.81 < \bar{\Delta} \leq \sigma/r_\epsilon = 7.63$ 的一支内 ($\bar{\Delta} > 7.63$ 时 $b = 1$ 亦不合规)，上述条件把合规的表逼成分段等宽的整数步长阶梯 ($\bar{\Delta}$ 更小的一支另有不等宽的合规解，如

$\{1, 3, 3\}$, $\bar{\Delta} = 7/3$ 、 $A_2 = 0.20\%$)；而实际压扩曲线的步长须随信号增长，故段与段之间必然存在边界；在边界的若干个 σ 邻域内组宽序列不再周期， P 的论证不适用。数值上， $3 \rightarrow 5$ 、 $5 \rightarrow 7$ 两种合规边界与 $4 \rightarrow 5$ 这一非合规对照 ($\bar{\Delta} = 4$ 已由第 X-C 节排除，合规等宽段只有奇数宽 1、3、5、7) 处的一阶偏置峰值分别为 $\bar{\Delta}$ (取两侧宽度的算术平均) 的 2.89%、3.01% 与 1.45%，分别比同一构造在较宽一侧段内的值高约 $10^{6.5}$ 、 $10^{2.8}$ 与 $10^{6.3}$ 倍，并均超出本文的 1% 容差；以较窄一侧为参照时倍数更大。该效应是局域的，落在信号电平的一个窄带上，本文不作进一步分析。

XI. 结论

量化输出的特征函数由输入特征函数在频率间隔 $2\pi/\Delta$ 处的副本加权求和。一阶条件矩的相位谐波由输入特征函数的格点值控制，二阶及更高阶矩还包含其导数项。对高斯时间读噪，这些项均带有 $\exp[-2\pi^2 k^2 (\sigma/\Delta)^2]$ ，因此直接目标位深量化的一阶均值结构与二阶能量调制随 $r = \sigma/\Delta$ 快速衰减。

第 VII 节的直接量化分区来自首谐波解析阈值，余项界保证其在表列阈值附近与完整级数一致。第 IX 节的两级分区取自完整离散和的数值稳定阈值。

16-bit 整数码经截位或 half-up 降至 14-bit 时，分别产生约 -1.5 与 $+0.5$ DN16 的固定码值偏移。校正后，两者的一阶、二阶幅度及任一相同目标 T 下的 DR 均与直接 Q4 相同，在 T_{PDR} 下的 PDR 也相同。ties-to-even 形成宽度为 5、3 的交替量化单元，其相位平均量化误差能量为 $19/12 \text{ DN}16^2$ ，比直接 Q4、中心化截位和中心化 half-up 多 $1/4 \text{ DN}16^2$ 。

图 18、图 19 使用同一相对容差比较两类模型。1% 容差下，直接量化的一阶、二阶阈值分别为 0.419 和 0.620，两级 ties-to-even 模型分别为 0.804 和 1.273。工程上取 0.8 与 1.3 后， $0.8 \leq r < 1.3$ 构成两级模型的二阶主导过渡区。

图 20 给出量化网络的相位含义，图 21 给出相位平均 MSE 与近黑 DR 极限。近黑 DR 极限由相位平均误差能量确定，一阶、二阶相位结构则描述条件矩随信号相位的周期起伏。两级链路的近黑 DR 损失可分解为直接 Q4 相对 Q1 的量化损失与 ties-to-even 的附加损失，两者均为 r 的函数；固定相位范围由 $M_2(s)$ 的峰峰值刻画，无限堆栈的极限则由未消失的一阶偏置决定。

压扩表作用在已量化的整数码流上，因而本身即第 IX 节的两级链路。其基波的相位阻尼由组宽序列的重复长度 P 决定 (P 取最小周期，以输入码计， $\bar{\Delta}$ 仅经 $P = b\bar{\Delta}$ 与之相关；且该描述只刻画阻尼，前因子另由组宽序列与 d_i 决定，并因含 σ^2 交叉项而亦随 σ 变)，设计条件为 $P \leq \sigma/r_\epsilon$ (量级判据，非严格的界)；在第 IV-B 节工作点与 1% 二阶容差下为 $P \leq 7.6$ 个输入码。该条件对任意序列等价于 $b \leq r/r_\epsilon$ (b 取最小周期内的组数， $P = b\bar{\Delta}$ 是定义)；只有对组宽尽量相等的序列， b 才等于 $\bar{\Delta}$ 最简分数的分母；在 $\bar{\Delta} > \sigma/(2r_\epsilon)$ 时这要求平均组宽取整数；但整数平均组宽只是必要条件：表 VII 中 ties-to-even 的平均组宽为 4 而 $P = 8$ ，仍给出 $A_2 = 2.60\%$ 。在整数重建且不允许小数黑电平校正时， $\bar{\Delta} > \sigma/(2r_\epsilon)$ 一支内的平均组宽须取奇整数，本工作点为 5 与 7；更小的 $\bar{\Delta}$ 另有可行解，不受此限 (如 $\{1, 3, 3\}$, $\bar{\Delta} = 7/3$ 、 $A_2 = 0.20\%$)； $\bar{\Delta} = 4$ 的最小重复长度为 8；由于 A_2 对 P 非单调，不可达性由 $b \leq 7$ 的直接穷举给出 (最小 $A_2 = 1.82\%$ ，按 $\bar{\Delta}^2/12$ 归一；改按 E_q 归一重新取极小， $b \leq 7$ 各档为 1.53%、45.4%、1.53%、16.1%、1.53%、10.9%，全局极小仍为 1.53%)； $b = 8$ 在全空间穷举 (2.1609×10^{11} 个有序构造，不设 d_i 的界)，最小周期确为 32 者的最小 $A_2 = 7.39\%$ (按 $\bar{\Delta}^2/12$ 归一)； $b > 8$ 未枚举，只有量级论证，故第 IX 节的 $A_2 = 2.60\%$ 不是规则选择不当所致，而 ties-to-even 在 $16 \rightarrow 14$ bit 的 4Z 重建约束下于所验范围内已是最优：该约束下 $b \leq 8$ 在全部组宽序列上穷举、 $b = 10$ 在组宽落于 $[1, 7]$ 者上穷举 (详见第 X-C 节；该约束在重建值随码单调的前提下使每个组宽序列至多对应一个构造，故无须再对重建偏移设界；该枚举中 $\max_i |\delta_i|$ 实达 $21/2$)。组宽不等另使相位平均量化能量升至 $\sum_i (w_i^3/12 + w_i d_i^2)/\sum_i w_i$ ；平滑压扩曲线则带一个与信号电平无关的直流偏置 $1/(12Kr^{*2})$ ，不随堆栈平均衰减，也不出现在相位平均误差能量中。

参考文献

- [1] I. Kollár, "Bias of Mean Value and Mean Square Value Measurements Based on Quantized Data," *IEEE Trans. Instrumentation and Measurement*, vol. 43, no. 5, pp. 733–739, 1994.
- [2] P. Carbone *et al.*, "Effect of Additive Dither on the Resolution of Ideal Quantizers," *IEEE Trans. Instrumentation and Measurement*, vol. 43, no. 3, pp. 389–396, 1994.
- [3] B. H. Pillman, W. E. Prentice, and M. E. Napoli, *Statistically Lossless Compression System and Method*, U.S. Patent 9,438,899 B1 (Exelis Inc.), 申请 2013-12-11, 授权 2016-09-06。(其权利要求 1 为：

- 映射到同一输出码的相邻输入码个数与该组输入码的标准差成正比；说明书给出 $\sigma = (mL + b)^{1/2}$ ，其中 b 为读噪偏置项。）
- [4] *Compression Techniques for Substantially Lossless Digital Image Data Storage*, U.S. Patent 5,790,705 (Apple Computer, Inc.), 申请 1996-09-13, 授权 1998-08-04. (其中给出量化步长与噪声的定量关系：步长至多为噪声的 $8/3$ ，即 $\sigma/\Delta \geq 3/8$ ；重建取区间中点。)
 - [5] G. M. Bernstein, C. Bebek, J. Rhodes, C. Stoughton, R. A. Vanderveld, and P. Yeh, “Noise and Bias in Square-Root Compression Schemes,” *Publications of the Astronomical Society of the Pacific*, vol. 122, no. 889, pp. 336–346, 2010. doi:10.1086/651281. arXiv:0910.4571.
 - [6] C. E. DeForest, C. Lowder, D. B. Seaton, and M. J. West, “Square Root Compression and Noise Effects in Digitally Transformed Images,” *The Astrophysical Journal*, 2022. doi:10.3847/1538-4357/ac7f3d. arXiv:2207.05601.
 - [7] R. A. Gowen and A. Smith, “Square root data compression,” *Review of Scientific Instruments*, vol. 74, no. 8, pp. 3853–3861, 2003.
 - [8] W. J. Claff, *Sensor Analysis Primer—Engineering and Photographic Dynamic Range*, Photons to Photos. https://www.photonstophotos.net/GeneralTopics/Sensors_&_Raw/Sensor_Analysis_Primer/Engineering_and_Photographic_Dynamic_Range.htm (PDR 以 $\text{SNR} = 20$ 配感光面对应的弥散圆归一；按像素高度写出即 $T_{\text{PDR}} = 16000/PH$) .
 - [9] E. Martinec, *Noise, Dynamic Range and Bit Depth in Digital SLRs*, 2008. <https://homes.psd.uchicago.edu/~ejmartin/pix/20d/tests/noise/> (镜像: <https://photonstophotos.net/Emil%20Martinec/noise.html>) .
 - [10] H. G. Dietz, “Sony ARW2 Compression: Artifacts and Credible Repair,” *Proc. IS&T Int. Symp. Electronic Imaging*, vol. 28, no. 2 (Visual Information Processing and Communication VII), pp. 1–10, 2016. doi:10.2352/ISSN.2470-1173.2016.2.VIPC-227.
 - [11] A. C. Popescu, *Statistical Tools for Digital Image Forensics*, Ph.D. dissertation, Dartmouth College, 2005, 第 4.2 节 (Double Quantization) .
 - [12] A. Zaman, *The Density of the Fractional Part of a Normal Distribution*, Lahore University of Management Sciences, 2004.
 - [13] W. R. Bennett, “Spectra of Quantized Signals,” *Bell System Technical Journal*, vol. 27, no. 3, pp. 446–472, 1948. doi:10.1002/j.1538-7305.1948.tb01340.x.
 - [14] W. F. Sheppard, “On the Calculation of the Most Probable Values of Frequency-Constants, for Data Arranged According to Equidistant Divisions of a Scale,” *Proc. London Mathematical Society*, vol. 29, pp. 353–380, 1898.
 - [15] B. Widrow, “A Study of Rough Amplitude Quantization by Means of Nyquist Sampling Theory,” *IRE Trans. Circuit Theory*, vol. 3, no. 4, pp. 266–276, 1956.
 - [16] B. Widrow, I. Kollár, and M.-C. Liu, “Statistical Theory of Quantization,” *IEEE Trans. Instrumentation and Measurement*, vol. 45, no. 2, pp. 353–361, 1996. doi:10.1109/19.492748.
 - [17] B. Widrow and I. Kollár, *Quantization Noise: Roundoff Error in Digital Computation, Signal Processing, Control, and Communications*, Cambridge University Press, 2008.
 - [18] A. B. Sripad and D. L. Snyder, “A Necessary and Sufficient Condition for Quantization Errors to be Uniform and White,” *IEEE Trans. Acoustics, Speech, and Signal Processing*, vol. 25, no. 5, pp. 442–448, 1977.
 - [19] R. M. Gray and D. L. Neuhoff, “Quantization,” *IEEE Trans. Information Theory*, vol. 44, no. 6, pp. 2325–2383, 1998. doi:10.1109/18.720541.
 - [20] R. M. Gray and T. G. Stockham, “Dithered Quantizers,” *IEEE Trans. Information Theory*, vol. 39, no. 3, pp. 805–812, 1993.
 - [21] A. G. Clavier, P. F. Panter, and D. D. Grieg, “Distortion in a Pulse Count Modulation System,” *Trans. AIEE*, vol. 66, pp. 989–1005, 1947.
 - [22] L. Schuchman, “Dither Signals and Their Effect on Quantization Noise,” *IEEE Trans. Communication Technology*, vol. 12, no. 4, pp. 162–165, 1964. doi:10.1109/TCOM.1964.1088973.
 - [23] S. P. Lipshitz, R. A. Wannamaker, and J. Vanderkooy, “Quantization and Dither: A Theoretical Survey,” *J. Audio Engineering Society*, vol. 40, no. 5, pp. 355–375, 1992.
 - [24] R. A. Wannamaker, S. P. Lipshitz, J. Vanderkooy, and J. N. Wright, “A Theory of Nonsubtractive Dither,” *IEEE Trans. Signal Processing*, vol. 48, no. 2, pp. 499–516, 2000. doi:10.1109/78.823976. (机制细节亦见 R. A. Wannamaker, *The Theory of Dithered Quantization*, Ph.D. thesis, Univ. of Waterloo, 1997.)
 - [25] J. Vanderkooy and S. P. Lipshitz, “Resolution Below the Least Significant Bit in Digital Systems with Dither,” *J. Audio Engineering Society*, vol. 32, no. 3, pp. 106–113, 1984.
 - [26] J. R. Janesick, *Photon Transfer: $DN \rightarrow \lambda$* , SPIE Press Monograph PM170, 2007. doi:10.1117/3.725073.
 - [27] EMVA, *Standard 1288: Standard for Characterization of Image Sensors and Cameras, Release 4.0 Linear*, European Machine Vision Association, 2021.
 - [28] M. Konnik and J. Welsh, “High-level numerical simulations of noise in CCD and CMOS photosensors: review and tutorial,” arXiv:1412.4031, 2014.
 - [29] P. G. J. Barten, *Contrast Sensitivity of the Human Eye and Its Effects on Image Quality*, SPIE Press, 1999.
 - [30] S. Miller, M. Nezamabadi, and S. Daly, “Perceptual Signal Coding for More Efficient Usage of Bit Codes,” *SMPTE Motion Imaging Journal*, vol. 122, no. 4, pp. 52–59, 2013.
 - [31] DICOM PS3.14, *Grayscale Standard Display Function (GSDF)*, NEMA.
 - [32] Rec. ITU-R BT.2100 / Report ITU-R BT.2246 (HDR 与 contouring 阈值, $8/10/12$ -bit) .
 - [33] C. Poynton, *Digital Video and HD: Algorithms and Interfaces*, 2nd ed., Morgan Kaufmann, 2012.
 - [34] 姜尧耕, *14bit RAW Delta PDR Critical ISO Curves*, project page, <https://y-g-jiang.github.io/PLT.html>.
 - [35] Y. Jiang (姜尧耕), *Impact of ISP Affine Re-quantization on Photon Transfer Characteristics and Perceptual Quality*, Zenodo preprint, 2025. doi:10.5281/zenodo.18949317 (该 DOI 存档的是 v4); 本文所引的 $\delta(r)$ 与相位谐波级数见其后续版本 v5, 见下述代码库。代码与更新: https://github.com/y-g-jiang/paper_IARPTC. (给出高斯输入下二阶首谐波半幅 $\Delta^2\delta(r)$ 、相对于 $\Delta^2/12$ 的归一化调制 $A_2(r) = 12\delta(r)$ ，以及非整数仿射再量化的相位振荡与相移分析。)
 - [36] F. J. Anscombe, “The Transformation of Poisson, Binomial and Negative-Binomial Data,” *Biometrika*, vol. 35, no. 3–4, pp. 246–254, 1948. (广义形式见 J.-L. Starck, F. Murtagh, A. Bijaoui, *Image Processing and Data Analysis*, Cambridge University Press, 1998.)
 - [37] W. D. Pence, R. Seaman, and R. L. White, *Fpack and Funpack User's Guide: FITS Image Compression Utilities*, arXiv:1112.2671, 2011.
 - [38] Adobe Inc., *Digital Negative (DNG) Specification*, Version 1.7.1.0, 2023. (LinearizationTable)